

*Leveraging linguistic annotations to improve
automatic detection of online content*

Nom : **Tsang**

Prénom : **Gwendal**

Département/Unité : Palaiseau – DTIS/MIDL

Thématique ICS

Encadrant(s) ONERA

Valentina Dragos

Formation

M2 TAL

Mots clés :

Objectifs

L'objectif de ce stage est d'étudier dans quelle mesure les signaux émotionnels peuvent compléter l'analyse de contenus toxiques en ligne, en particulier dans des messages liés au cyberharcèlement adolescent. Le travail porte à la fois sur des ressources lexicales, des annotations linguistiques fines et l'évaluation d'un modèle neuronal existant de détection des émotions.

Contexte

J'ai fait mon stage dans le service MIDL du DTIS. Le sujet est interdisciplinaire : il croise linguistique de corpus, psycholinguistique des émotions et apprentissage automatique appliqué à la détection de contenus abusifs (*Abusive Language Detection*).

La détection automatique des émotions repose historiquement sur des lexiques émotionnels associant des lemmes à des catégories affectives. Nous avons testé ceux développés par Étienne [1], dont le modèle s'appuie également sur une lemmatisation (Stanza). Nous partageons son constat : les lexiques seuls ne suffisent pas à capter la richesse de l'expression émotionnelle, en particulier dans les messages adolescents (abréviations, graphies non standard, sarcasme).¹

Pour dépasser cette limite, le stage a mobilisé deux familles d'approches complémentaires. D'une part, EMOTYC, un classifieur RoBERTa multi-label issu de la chaîne TextToKids [2], qui prédit 19 labels (présence d'émotion, mode d'expression, catégorie émotionnelle).² D'autre part, des classifieurs linéaires (TF-IDF + LinearSVC, scikit-learn) testés comme baselines. Ce choix fait écho aux résultats de Dragos et Constable [3], qui observent que SVM + TF-IDF surpasse des modèles neuronaux plus lourds pour la détection d'extrémisme en français. Les résultats comparatifs sont présentés dans les sections suivantes.

J'ai par ailleurs annoté manuellement 781 messages issus de *CyberAgression-Large* pour produire le gold émotionnel *CyberAggAdo*, compatible avec les sorties d'EMOTYC.³




FIGURE 1 – Schéma du modèle EMOTYC.

1. Scripts d'extraction et de correspondance lexicale : [ExpressionEmotionnelle](#).

2. EMOTYC : [site officiel](#), [démon](#), [dépôt](#).

3. Gold et visualisations : [Visualisation des annotations](#), [Visualisations corpus CyberAggAdo](#), [Visualisation corpus TextToKids](#).

Objectifs scientifiques

La modélisation automatique des émotions ne peut toutefois se réduire à l'identification de lexiques émotionnels explicites. Étienne [1] distingue quatre modes d'expression, repris ici :

Mode	Définition synthétique
Désignée	émotion nommée par un terme du lexique affectif
Comportementale	émotion inférée à partir d'une manifestation physique, discursive ou observable
Suggérée	émotion inférée à partir d'une situation ou d'un événement typiquement associé
Montrée	émotion portée par la forme même de l'énoncé : syntaxe, ponctuation, typographie ou interjection

Les travaux de Dragos et al. [4] mettent en évidence la difficulté à localiser des indices émotionnels diffus, implicites ou dépendants du contexte.

Les objectifs scientifiques du stage consistent donc à dépasser une lecture strictement lexicale ou binaire des contenus toxiques, à examiner empiriquement le comportement de modèles d'analyse émotionnelle existants et à déterminer comment leurs sorties peuvent être interprétées pour caractériser plus finement des corpus issus des réseaux sociaux.

Démarche, déroulement et principaux résultats obtenus

0.1 Corpus, ressources et scripts mobilisés

Le travail a combiné plusieurs types de ressources. D'une part, le corpus *CyberAggAdo* a servi de terrain d'étude principal pour l'analyse de messages de cyberagression adolescente. D'autre part, les résultats sur *TextToKids* ont fourni un point de comparaison avec le domaine d'entraînement d'EMOTYC. Les fichiers de référence, les scripts d'inférence et les sorties d'évaluation sont regroupés dans les dépôts associés au stage.⁴

Un second volet a porté sur les marqueurs émotionnels et leur relation aux émotions et aux modes d'expression. Cette partie s'appuie sur la pipeline *ExpressionEmotionnelle*, sur le corpus *SimpleSitEmo* et sur les rapports statistiques produits à partir des annotations de *CyberAggAdo*.⁵

0.2 Annotations linguistiques fines et modèle EMOTION

Le premier axe d'analyse a porté sur le module lexical *EMOTION*, qui associe des lemmes à des catégories émotionnelles.⁶ Cette approche est interprétable et frugale, mais elle reste fragile face aux abréviations, graphies non standard, usages sarcastiques et variations contextuelles des messages adolescents.

0.3 Tests du modèle EMOTYC

Le modèle EMOTYC a été développé dans le cadre du projet ANR TextToKids [1, 2].⁷ Il s'agit d'un fine-tuning de CamemBERT [5], entraîné pour une classification multi-label à 19 sorties : présence d'une émotion, mode d'expression, niveau *BaselComplexe* et catégorie émotionnelle.

Les évaluations réalisées pendant le stage ont principalement repris la configuration contextuelle utilisée pour le modèle : la phrase cible est fournie avec son contexte immédiat, c'est-à-dire les phrases précédente et suivante. Sur *TextToKids* (27 911 unités), EMOTYC obtient un Macro-F1 de 0,739 et un Micro-F1 de 0,897. Sur *CyberAggAdo* (781 unités), ces scores chutent à 0,282 et 0,472 respectivement. Plutôt que de reproduire les tableaux détaillés label par label, les deux heatmaps suivantes synthétisent visuellement l'écart de transfert $\Delta_m(\ell) = m_{\text{TextToKids}}(\ell) - m_{\text{CyberAggAdo}}(\ell)$. La couleur encode l'amplitude de $|\Delta|$: vert clair si les performances sont proches, orange à rouge si l'écart est important.

On voit que le mode *Suggérée* et le label *Autre* présentent les écarts les plus marqués.

4. Évaluations EMOTYC : [dépôt](#), [rapport](#), [résultats](#).

5. Marqueurs et corrélations : [dépôt](#), [résultats](#).

6. Lexique et appariements : [lexique](#), [résultats](#).

7. Modèle et publications : [Hugging Face](#), [TextToKids](#).

Label	Cyber	ΔF_1	ΔP	ΔR
Émo	398	+0.27	+0.31	+0.23
Base	363	+0.37	+0.29	+0.43
Montrée	300	+0.41	+0.42	+0.41
Colère	289	+0.46	+0.42	+0.49
Autre	62	+0.76	+0.78	+0.68

TABLE 1 – Heatmap des écarts de performance entre *TextToKids* et *CyberAggAdo*.

Label	Cyber	TTK	ΔF_1	ΔP	ΔR
Autre	62	1 270	+0.76	+0.78	+0.68
Suggérée	54	1 909	+0.73	+0.67	+0.74
Désignée	55	1 499	+0.56	+0.50	+0.60
Colère	289	1 180	+0.46	+0.42	+0.49
Montrée	300	971	+0.41	+0.42	+0.41
Base	363	4 133	+0.37	+0.29	+0.43

TABLE 2 – Labels concentrant le plus fort décrochage entre *TextToKids* et *CyberAggAdo*.

Transposition aux réseaux sociaux

L'application d'EMOTYC à des données issues des réseaux sociaux s'accompagne d'écarts de performance par rapport au domaine d'entraînement. Dragos et al. [6] utilisent EMOTYC pour étudier la densité émotionnelle de corpus extrémistes, sexistes et haineux issus de Twitter et de forums. Les heatmaps ci-dessus documentent ces écarts : le modèle conserve une détection globale de l'émotion ($\Delta F_1 = +0,27$), mais les performances baissent nettement pour les modes d'expression et les catégories émotionnelles. Le mode *Suggérée* décroche fortement ($\Delta F_1 = +0,73$), ce qui indique que les indices contextuels appris sur *TextToKids* transfèrent mal vers les messages de cyberharcèlement. Le label *Autre* présente le plus grand écart parmi les labels ayant au moins 50 occurrences positives dans *CyberAggAdo*.⁸

Dans ce contexte, l'extraction automatique des signaux émotionnels conserve un intérêt analytique. Dragos et al. [6] montrent que la colère domine les corpus étudiés, mais que sa densité varie selon les types de contenus : elle représente 61,5 % des émotions dans les textes haineux, contre 15,6 % dans les contenus non haineux. À l'inverse, l'admiration apparaît davantage dans les contenus non haineux. Ces résultats indiquent que le profil émotionnel peut contribuer à caractériser les contenus toxiques et à compléter les approches strictement binaires de la toxicité en ligne [6, 7].

0.4 Résultats descriptifs sur CyberAggAdo

Les analyses statistiques réalisées sur les annotations de *CyberAggAdo* indiquent que certaines émotions et certains modes sont associés au degré d'agressivité annoté.⁹ La colère et le dégoût sont plus fréquents dans les messages d'agressivité ouverte (OAG) que dans les messages non agressifs ou couverts. Le mode *Montrée* est de son côté le mode le plus associé à l'agressivité ouverte.

Ces observations ne se substituent pas à une annotation manuelle ni à une évaluation de modèle. Elles fournissent plutôt un ensemble d'indices descriptifs permettant de relier les émotions, les modes d'expression, les rôles interactionnels et les catégories d'agressivité déjà présentes dans le corpus. Elles justifient l'intérêt d'articuler plusieurs niveaux d'analyse : lexicale émotionnelle, marqueurs linguistiques, annotations conversationnelles et sorties de modèles.

Perspectives

Plusieurs prolongements peuvent être envisagés à partir des ressources produites. Une première piste consiste à mieux distinguer les configurations d'évaluation d'EMOTYC : avec ou sans contexte, seuil fixe ou seuil calibré, corpus continu ou échantillon non contigu. Cette distinction est importante car le contexte immédiat n'a pas le même statut

8. Analyse d'erreurs : [rapport](#), [sorties](#).

9. Rapports de corrélation : [émotions](#), [modes](#).

dans un texte continu de *TextToKids* et dans une conversation de cyberagression où les messages adjacents peuvent changer de locuteur, de cible ou d'intention.

Une deuxième piste consiste à appliquer un post-traitement logique aux sorties multi-labels. Lorsqu'une catégorie émotionnelle est prédite, le label global d'émotion devrait être cohérent avec cette prédiction ; de même, les labels *Base* et *Complexe* peuvent être dérivés des catégories émotionnelles plutôt que prédits indépendamment.

Une troisième piste concerne la normalisation contrôlée du langage numérique : abréviations, argot, allongements graphiques, fautes fréquentes et formes propres aux interactions adolescentes. Cette normalisation doit rester prudente, car certaines graphies non standard sont aussi des indices expressifs. Les scripts de *ExpressionEmotionnelle* offrent un point de départ pour relier ces formes aux marqueurs émotionnels, au lexique et aux annotations de mode.

Enfin, les variables déjà présentes dans *CyberAggAdo*, telles que `ROLE`, `TARGET`, `HATE`, `INTENTION` ou `SENTIMENT`, peuvent être utilisées comme variables d'analyse ou comme informations complémentaires dans de futures expériences. L'objectif serait de mieux décrire la relation entre émotion, agressivité, cible et position interactionnelle, sans réduire la détection du cyberharcèlement à une simple classification binaire.

Références

- [1] A. Etienne, *Analyse automatique des émotions dans les textes : contributions théoriques et applicatives dans le cadre de l'étude de la complexité des textes pour enfants*, Thèse de doctorat, Université de Nanterre-Paris X (2023).
- [2] A. Étienne, D. Battistelli et G. Lecorvé, *Emotion Identification for French in Written Texts : Considering their Modes of Expression as a Step Towards Text Complexity Analysis* (2024).
- [3] V. Dragos et Y. Constable, *Comparison of Classification Techniques for Extremism Detection in French Social Media*, Dans *2023 26th International Conference on Information Fusion (FUSION)*, pp. 1–6. IEEE (2023).
- [4] V. Dragos, D. Battistelli, A. Etienne et Y. Constable, *Angry or sad? emotion annotation for extremist content characterisation*, Dans *Proceedings of the Thirteenth Language Resources and Evaluation Conference*, pp. 193–201 (2022).
- [5] L. Martin, B. Muller, P. J. Ortiz Suárez, Y. Dupont, L. Romary, É. de la Clergerie, D. Seddah et B. Sagot, *CamemBERT : a Tasty French Language Model*, Dans *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics*, pp. 7203–7219. Association for Computational Linguistics (2020).
- [6] V. Dragos, D. Battistelli, F. Sow et A. Etienne, *Exploring the Emotional Dimension of French Online Toxic Content*, Dans *Proceedings of the 2024 Joint International Conference on Computational Linguistics, Language Resources and Evaluation (LREC-COLING 2024)*, pp. 6945–6954 (2024).
- [7] D. Battistelli, F. Benamara et V. Patti, *Introduction to the Special Issue of the TAL Journal on Abusive Language : Linguistic Resources, Methods and Applications*, *Traitement Automatique des Langues*, 65 (3), pp. 7–20 (2025).