

Analyse automatique des émotions dans les contenus toxiques en ligne

Nom : Tsang

Prénom : Gwendal

Département/Unité : Palaiseau – DTIS MTIS

Thématique ICS

Encadrant(s) ONERA

À compléter

Formation

Master 2 Traitement Automatique des Langues

Mots clés : émotions, toxicité en ligne, TAL, CamemBERT, EMOTYC

Objectifs

L'objectif de ce stage est d'étudier dans quelle mesure les signaux émotionnels peuvent compléter ou apporter un nouvel éclairage sur la détection du cyberharcèlement.

Contexte

L'analyse automatique des émotions et de la toxicité en ligne (*Abusive Language Detection*) se heurte à plusieurs limites et difficultés. Les approches reposant uniquement sur une classification binaire échouent souvent à capturer la complexité linguistique et pragmatique des contenus, notamment lorsque la violence discursive s'exprime de manière implicite ou indirecte [1].

Cette limite est illustrée par Dragos et Constable [2], qui comparent différentes techniques de classification pour la détection de contenus extrémistes en français à partir d'un corpus de 1 728 textes. Leur étude confronte des modèles classiques, tels que les SVM associés à des représentations TF-IDF, Bag-of-Words ou à des traits linguistiques, à un modèle de langue pré-entraîné de type CamemBERT. Après rééquilibrage des données par SMOTE, CamemBERT obtient de bonnes performances, avec une exactitude de 0,78, une précision de 0,80, un rappel de 0,86 et une F-mesure de 0,79. Toutefois, un modèle plus classique, combinant SVM et TF-IDF, atteint des résultats comparables, voire supérieurs en rappel, avec une F-mesure de 0,83.

Ces résultats montrent que l'ajout de traits linguistiques de surface ne garantit pas une amélioration des performances : dans l'étude de Dragos et Constable [2], leur intégration au SVM entraîne au contraire une dégradation notable, la F-mesure chutant à 0,54. Les auteurs soulignent ainsi la difficulté à détecter l'extrémisme à partir de marqueurs génériques, en raison du caractère fuyant, contextuel et fortement subjectif de ce type de contenu. Cette limite justifie le recours à des marqueurs sémantiques plus profonds, parmi lesquels les émotions occupent une place centrale.

Objectifs scientifiques

La modélisation automatique des émotions ne peut toutefois se réduire à l'identification de lexiques émotionnels explicites. Étienne [3] montre les limites des approches fondées sur des ressources lexicales classiques et propose un schéma d'annotation distinguant quatre modes d'expression de l'émotion : le mode *désigné*, lorsque l'émotion est exprimée par un lexique explicite ; le mode *comportemental*, lorsqu'elle est associée à des manifestations physiques ou observables ; le mode *montré*, lorsqu'elle apparaît à travers des indices syntaxiques, typographiques ou discursifs ; et le mode *suggéré*, lorsqu'elle doit être inférée à partir du contexte socioculturel ou situationnel.

Les travaux de Dragos et al. [4] confirment la complexité d'un tel schéma lorsqu'il est appliqué à des contenus extrémistes. Dans leur étude consacrée à l'annotation émotionnelle de contenus extrémistes, les auteurs observent un accord satisfaisant pour l'identification des catégories émotionnelles, avec un rappel de 0,86, mais des performances beaucoup plus faibles pour la délimitation précise des déclencheurs linguistiques de l'émotion, avec une F-mesure de 0,54. Ce résultat met en évidence la difficulté à localiser précisément les indices émotionnels dans des discours où l'affect peut être diffus, implicite ou fortement dépendant du contexte.

Les objectifs scientifiques du stage consistent donc à dépasser une lecture strictement lexicale ou binaire des contenus toxiques, à examiner la robustesse des modèles d’analyse émotionnelle existants et à déterminer comment leurs sorties peuvent être interprétées pour caractériser plus finement des corpus issus des réseaux sociaux.

Démarche, déroulement et principaux résultats obtenus

0.1 Annotations linguistiques fines

0.2 Tests du modèle EMOTYC

Le modèle [EMOTYC](<https://huggingface.co/TextToKids/CamemBERT-base-EmoTextToKids>) a été développé par [3] dans le cadre du projet [ANR TextToKids](<https://texttokids.irisa.fr/publications/>) . Il s’agit d’un modèle transformers qui permet de faire une classification multi-tâches : le modèle a été entraîné à prédire à la fois la présence d’une émotion, son mode d’expression et sa catégorie émotionnelle.




FIGURE 1 – Schéma du modèle EMOTYC.

Les évaluations réalisées pendant le stage ont repris cette configuration contextuelle : la phrase cible est fournie avec son contexte immédiat, c’est-à-dire les phrases précédente et suivante. Les scripts d’évaluation, les données intermédiaires et les exports de résultats sont disponibles dans le dépôt Eval-EMOTYC. Les tableaux suivants synthétisent les performances obtenues à partir des fichiers `emotyc_predictions_summary.json`, avec un seuil de décision fixé à 0,5.

Corpus	Exemples	Étiquettes	Macro-F1	Micro-F1
<i>TextToKids</i>	27 911	19	0,739	0,897
<i>CyberAggAdo</i> global	781	19	0,282	0,473

TABLE 1 – Performances globales d’EMOTYC sur les deux corpus évalués.

Étiquette	Support	Précision	Rappel	F1	Kappa
<i>Présence et niveau de complexité</i>					
Émotion présente	5 374	0,927	0,933	0,930	0,914
Base	4 133	0,923	0,910	0,916	0,902
Complexe	568	0,904	0,798	0,848	0,845
<i>Modes d'expression</i>					
Comportementale	1 242	0,893	0,895	0,894	0,889
Désignée	1 499	0,925	0,929	0,927	0,923
Montrée	971	0,900	0,872	0,886	0,882
Suggérée	1 909	0,833	0,800	0,816	0,803
<i>Catégories émotionnelles</i>					
Admiration	211	0,854	0,664	0,747	0,745
Autre	1 270	0,886	0,921	0,903	0,898
Colère	1 180	0,915	0,917	0,916	0,913
Culpabilité	19	0,000	0,000	0,000	0,000
Dégoût	52	1,000	0,077	0,143	0,143
Embarras	162	0,818	0,778	0,798	0,796
Fierté	202	0,840	0,777	0,807	0,806
Jalousie	7	0,000	0,000	0,000	0,000
Joie	888	0,912	0,853	0,881	0,878
Peur	1 047	0,894	0,886	0,890	0,886
Surprise	824	0,913	0,886	0,899	0,896
Tristesse	673	0,865	0,817	0,840	0,837

TABLE 2 – Performances détaillées d’EMOTYC sur *TextToKids* avec contexte. Le support correspond au nombre d’occurrences positives dans l’annotation de référence.

Sur *TextToKids*, les performances sont élevées pour la présence d’une émotion, les modes d’expression et les catégories les plus représentées, avec une F1 supérieure à 0,88 pour la colère, la joie, la peur, la surprise, le mode *désigné* et le mode *comportemental*. Les résultats restent en revanche fragiles pour les classes très rares, comme la culpabilité, la jalousie ou le dégoût, où le support faible rend les scores instables malgré une exactitude globale élevée.

Transposition aux réseaux sociaux

La transposition d’un modèle tel qu’EMOTYC à des données issues des réseaux sociaux met en évidence des limites importantes de généralisation. Dragos et al. [5] utilisent EMOTYC comme outil d’analyse automatique afin d’étudier la densité émotionnelle de corpus extrémistes, sexistes et haineux issus de Twitter et de forums. L’évaluation menée sur le corpus *CyberAggAdo* global confirme cette baisse de robustesse dans des contextes discursifs plus bruités, plus courts et souvent plus implicites que ceux de son corpus d’entraînement.

Étiquette	Support	Précision	Rappel	F1	Kappa
<i>Présence et niveau de complexité</i>					
Émotion présente	398	0,620	0,706	0,660	0,258
Base	363	0,633	0,485	0,549	0,245
Complexe	14	0,212	0,500	0,298	0,280
<i>Modes d'expression</i>					
Comportementale	36	0,278	0,139	0,185	0,159
Désignée	55	0,429	0,327	0,371	0,330
Montrée	300	0,481	0,463	0,472	0,152
Suggérée	54	0,158	0,056	0,082	0,048
<i>Catégories émotionnelles</i>					
Admiration	0	0,000	0,000	0,000	–
Autre	62	0,106	0,242	0,148	0,042
Colère	289	0,492	0,429	0,458	0,173
Culpabilité	3	0,000	0,000	0,000	0,000
Dégoût	80	0,000	0,000	0,000	0,000
Embarras	2	0,071	1,000	0,133	0,129
Fierté	3	0,750	1,000	0,857	0,857
Jalousie	6	0,000	0,000	0,000	0,000
Joie	30	0,423	0,367	0,393	0,370
Peur	4	0,154	0,500	0,235	0,229
Surprise	5	0,333	0,400	0,364	0,359
Tristesse	14	0,115	0,214	0,150	0,130

TABLE 3 – Performances détaillées d’EMOTYC sur le corpus *CyberAggAdo* global avec contexte. Le support correspond au nombre d’occurrences positives dans l’annotation de référence.

Les performances observées sur *CyberAggAdo* sont nettement inférieures à celles obtenues sur *TextToKids*. La présence d’une émotion reste la tâche la plus robuste, avec une F1 de 0,660, mais l’identification des modes d’expression et des catégories émotionnelles chute fortement : le mode *suggéré* atteint seulement 0,082 de F1 et la colère, pourtant très présente dans le corpus, atteint 0,458 de F1. Ces écarts confirment la sensibilité du modèle à son domaine d’entraînement et la difficulté à transférer directement un modèle appris sur des textes plus normés vers des productions adolescentes en ligne.

Malgré ces limites, l’extraction automatique des signaux émotionnels offre un apport analytique important. Dragos et al. [5] montrent que la colère domine les corpus étudiés, mais que sa densité varie fortement selon les types de contenus : elle représente 61,5 % des émotions dans les textes haineux, contre 15,6 % dans les contenus non haineux. À l’inverse, l’admiration apparaît davantage dans les contenus non haineux. Ces résultats confirment que le profil émotionnel, même imparfaitement extrait, constitue une signature pertinente pour caractériser les contenus toxiques et dépasser les approches strictement binaires de la toxicité en ligne [5, 1].

Perspectives

Références

- [1] D. Battistelli, F. Benamara et V. Patti, *Introduction to the Special Issue of the TAL Journal on Abusive Language : Linguistic Resources, Methods and Applications*, Traitement Automatique des Langues, 65 (3), pp. 7–20 (2025).
- [2] V. Dragos et Y. Constable, *Comparison of Classification Techniques for Extremism Detection in French Social Media*, Dans *2023 26th International Conference on Information Fusion (FUSION)*, pp. 1–6. IEEE (2023).
- [3] A. Etienne, *Analyse automatique des émotions dans les textes : contributions théoriques et applicatives dans le cadre de l’étude de la complexité des textes pour enfants*, Thèse de doctorat, Université de Nanterre-Paris X (2023).
- [4] V. Dragos, D. Battistelli, A. Etienne et Y. Constable, *Angry or sad? emotion annotation for extremist content characterisation*, Dans *Proceedings of the Thirteenth Language Resources and Evaluation Conference*, pp. 193–201 (2022).
- [5] V. Dragos, D. Battistelli, F. Sow et A. Etienne, *Exploring the Emotional Dimension of French Online Toxic Content*, Dans *Proceedings of the 2024 Joint International Conference on Computational Linguistics, Language Resources and Evaluation (LREC-COLING 2024)*, pp. 6945–6954 (2024).