

Analyse automatique des émotions dans les contenus toxiques en ligne

Nom : Tsang

Prénom : Gwendal

Département/Unité : Palaiseau – DTIS/MIDL

Thématique ICS

Encadrant(s) ONERA

Delphine Battistelli
Valentina Dragos

Formation

Master 2 Traitement Automatique des Langues

Mots clés : émotions, cyberharcèlement, toxicité en ligne, TAL, CamemBERT, EMOTYC

Objectifs

L'objectif de ce stage est d'étudier dans quelle mesure les signaux émotionnels peuvent compléter l'analyse de contenus toxiques en ligne, en particulier dans des messages liés au cyberharcèlement adolescent. Le travail porte à la fois sur des ressources lexicales, des annotations linguistiques fines et l'évaluation d'un modèle neuronal existant de détection des émotions.

Les développements et résultats mobilisés dans ce résumé sont répartis dans trois dépôts : [Eval-EMOTYC](#), consacré à l'évaluation du modèle EMOTYC ; [EMOTYC](#), consacré à l'inférence et à l'analyse complémentaire du modèle ; et [ExpressionEmotionnelle](#), consacré aux ressources lexicales, aux marqueurs émotionnels et aux analyses statistiques associées.

Contexte

Le stage s'inscrit dans les travaux du service MIDL du DTIS sur l'analyse automatique de contenus toxiques et de cyberharcèlement. Le corpus principalement étudié est *CyberAggAdo*, disponible dans les répertoires [gold/](#) du dépôt Eval-EMOTYC et [data/](#) du dépôt EMOTYC. Il contient des messages courts, souvent conversationnels, annotés avec des informations relatives à l'agressivité, aux rôles interactionnels, aux cibles et aux émotions.

L'analyse automatique des émotions et de la toxicité en ligne (*Abusive Language Detection*) se heurte à plusieurs difficultés. Les approches reposant uniquement sur une classification binaire décrivent imparfaitement la complexité linguistique et pragmatique des contenus, notamment lorsque la violence discursive s'exprime de manière implicite ou indirecte [1].

Cette limite est illustrée par Dragos et Constable [2], qui comparent différentes techniques de classification pour la détection de contenus extrémistes en français à partir d'un corpus de 1 728 textes. Leur étude confronte des modèles classiques, tels que les SVM associés à des représentations TF-IDF, Bag-of-Words ou à des traits linguistiques, à un modèle de langue pré-entraîné de type CamemBERT. Après rééquilibrage des données par SMOTE, CamemBERT obtient de bonnes performances, avec une exactitude de 0,78, une précision de 0,80, un rappel de 0,86 et une F-mesure de 0,79. Toutefois, un modèle plus classique, combinant SVM et TF-IDF, atteint des résultats comparables, voire supérieurs en rappel, avec une F-mesure de 0,83.

Ces résultats montrent que l'ajout de traits linguistiques de surface ne garantit pas une amélioration des performances : dans l'étude de Dragos et Constable [2], leur intégration au SVM entraîne au contraire une dégradation notable, la F-mesure chutant à 0,54. Les auteurs soulignent ainsi la difficulté à détecter l'extrémisme à partir de marqueurs génériques, en raison du caractère fuyant, contextuel et fortement subjectif de ce type de contenu. Cette limite justifie le recours à des marqueurs sémantiques plus profonds, parmi lesquels les émotions occupent une place centrale.

Objectifs scientifiques

La modélisation automatique des émotions ne peut toutefois se réduire à l'identification de lexiques émotionnels explicites. Étienne [3] montre les limites des approches fondées sur des ressources lexicales classiques et propose un schéma d'annotation distinguant quatre modes d'expression de l'émotion : le mode *désigné*, lorsque l'émotion est

exprimée par un lexique explicite ; le mode *comportemental*, lorsqu'elle est associée à des manifestations physiques ou observables ; le mode *montré*, lorsqu'elle apparaît à travers des indices syntaxiques, typographiques ou discursifs ; et le mode *suggéré*, lorsqu'elle doit être inférée à partir du contexte socioculturel ou situationnel.

Les travaux de Dragos et al. [4] confirment la complexité d'un tel schéma lorsqu'il est appliqué à des contenus extrémistes. Dans leur étude consacrée à l'annotation émotionnelle de contenus extrémistes, les auteurs observent un accord satisfaisant pour l'identification des catégories émotionnelles, avec un rappel de 0,86, mais des performances beaucoup plus faibles pour la délimitation précise des déclencheurs linguistiques de l'émotion, avec une F-mesure de 0,54. Ce résultat met en évidence la difficulté à localiser précisément les indices émotionnels dans des discours où l'affect peut être diffus, implicite ou fortement dépendant du contexte.

Les objectifs scientifiques du stage consistent donc à dépasser une lecture strictement lexicale ou binaire des contenus toxiques, à examiner empiriquement le comportement de modèles d'analyse émotionnelle existants et à déterminer comment leurs sorties peuvent être interprétées pour caractériser plus finement des corpus issus des réseaux sociaux.

Démarche, déroulement et principaux résultats obtenus

0.1 Corpus, ressources et scripts mobilisés

Le travail a combiné plusieurs types de ressources. D'une part, le corpus *CyberAggAdo* a servi de terrain d'étude principal pour l'analyse de messages de cyberagression adolescente. D'autre part, les résultats sur *TextToKids* ont fourni un point de comparaison avec le domaine d'entraînement d'EMOTYC. Les fichiers de référence et les sorties d'évaluation sont regroupés dans [Eval-EMOTYC/results/](#), notamment le rapport de synthèse [rapport_performances.md](#) et les fichiers [emotyc_predictions_summary.json](#).

Un second volet a porté sur les marqueurs émotionnels et leur relation aux émotions et aux modes d'expression. Cette partie s'appuie sur le dépôt [ExpressionEmotionnelle](#), en particulier la pipeline [pipeline/run_analysis.py](#), le corpus [SimpleSitEmo.parquet](#), les sorties [results/simplesitemo/](#) et les rapports de corrélation entre agressivité et émotions ou modes d'expression [hate_emotions_correlation_report.md](#) et [hate_modes_correlation_report.md](#).

0.2 Annotations linguistiques fines et modèle EMOTION

Le premier axe d'analyse a porté sur le module lexical *EMOTION*. Ce module repose sur le fichier [lexique_emotionnel.tsv](#), qui associe des termes émotionnels à des catégories. Son principe est déterministe : après tokenisation, lemmatisation et filtrage de mots outils, chaque lemme est comparé aux entrées du lexique ; lorsqu'une entrée est trouvée, la catégorie correspondante est activée et les proportions de catégories sont calculées pour la séquence analysée. La lemmatisation est assurée par Stanza dans le module initial, tandis que les scripts de [pipeline/nlp_utils.py](#) permettent aussi de comparer des extractions avec spaCy.

Cette approche présente un intérêt méthodologique important : elle est interprétable, frugale et directement inspectable. Elle permet notamment d'examiner les catégories lexicales présentes dans les messages, par exemple les catégories liées au *mépris*, au *ressentiment*, à la *colère* ou au *dégoût*. Elle met aussi en évidence des limites attendues sur des messages adolescents : abréviations, fautes de frappe, graphies non standard, usages sarcastiques et variabilité contextuelle des termes émotionnels.

Un audit local du lexique et des marqueurs extraits a également permis d'identifier des points de normalisation utiles. Le lexique contient 1 420 entrées, sans doublon apparent de terme, mais une variation de libellé entre *degout* et *dégoût* doit être harmonisée avant d'annoncer le nombre de catégories distinctes. Les scripts de comparaison entre marqueurs et lexique, notamment [tools/match_marker_values_to_lexicon.py](#), produisent des tableaux de correspondance et de propositions de réparation dans [results/simplesitemo_lexicon_matching/](#).

0.3 Tests du modèle EMOTYC

Le modèle EMOTYC a été développé dans le cadre du projet ANR TextToKids [3, 5]. Il s'agit d'un modèle de type CamemBERT entraîné pour une classification multi-label : il prédit la présence d'une émotion, son niveau *Base/Complexe*, son mode d'expression et sa catégorie émotionnelle.

Les évaluations réalisées pendant le stage ont principalement repris la configuration contextuelle utilisée pour le modèle : la phrase cible est fournie avec son contexte immédiat, c'est-à-dire les phrases précédente et suivante.




FIGURE 1 – Schéma du modèle EMOTYC.

Les scripts d'évaluation, les données intermédiaires et les exports de résultats sont disponibles dans le dépôt [Eval-EMOTYC](#), en particulier [orchestrate_emotyc_folder.py](#), [emotyc_predict.py](#) et les sorties [results/](#). Les tableaux suivants synthétisent les performances obtenues avec un seuil de décision fixé à 0,5.

Corpus	Exemples	Étiquettes	Macro-F1	Micro-F1
<i>TextToKids</i>	27 911	19	0,739	0,897
<i>CyberAggAdo</i> global	781	19	0,282	0,472

TABLE 1 – Performances globales d'EMOTYC sur les deux corpus évalués.

Étiquette	Support	Précision	Rappel	F1	Kappa
<i>Présence et niveau de complexité</i>					
Émotion présente	5 374	0,927	0,933	0,930	0,914
Base	4 133	0,923	0,910	0,916	0,902
Complexe	568	0,904	0,798	0,848	0,845
<i>Modes d'expression</i>					
Comportementale	1 242	0,893	0,895	0,894	0,889
Désignée	1 499	0,925	0,929	0,927	0,923
Montrée	971	0,900	0,872	0,886	0,882
Suggérée	1 909	0,833	0,800	0,816	0,803
<i>Catégories émotionnelles</i>					
Admiration	211	0,854	0,664	0,747	0,745
Autre	1 270	0,886	0,921	0,903	0,898
Colère	1 180	0,915	0,917	0,916	0,913
Culpabilité	19	0,000	0,000	0,000	0,000
Dégoût	52	1,000	0,077	0,143	0,143
Embarras	162	0,818	0,778	0,798	0,796
Fierté	202	0,840	0,777	0,807	0,806
Jalousie	7	0,000	0,000	0,000	0,000
Joie	888	0,912	0,853	0,881	0,878
Peur	1 047	0,894	0,886	0,890	0,886
Surprise	824	0,913	0,886	0,899	0,896
Tristesse	673	0,865	0,817	0,840	0,837

TABLE 2 – Performances détaillées d'EMOTYC sur *TextToKids* avec contexte. Le support correspond au nombre d'occurrences positives dans l'annotation de référence.

Sur *TextToKids*, les performances sont élevées pour la présence d'une émotion, les modes d'expression et les catégories les plus représentées, avec une F1 supérieure à 0,88 pour la colère, la joie, la peur, la surprise, le mode *désigné* et le mode *comportemental*. Les résultats restent en revanche fragiles pour les classes très rares, comme la culpabilité, la jalousie ou le dégoût, où le support faible rend les scores instables malgré une exactitude globale élevée.

Transposition aux réseaux sociaux

La transposition d'un modèle tel qu'EMOTYC à des données issues des réseaux sociaux s'accompagne d'écarts de performance par rapport au domaine d'entraînement. Dragos et al. [6] utilisent EMOTYC comme outil d'analyse automatique afin d'étudier la densité émotionnelle de corpus extrémistes, sexistes et haineux issus de Twitter et de forums. L'évaluation menée sur le corpus *CyberAggAdo* global documente ces écarts dans des contextes discursifs plus bruités, plus courts et souvent plus implicites que ceux de son corpus d'entraînement.

Étiquette	Support	Précision	Rappel	F1	Kappa
<i>Présence et niveau de complexité</i>					
Émotion présente	398	0,620	0,706	0,660	0,258
Base	363	0,633	0,485	0,549	0,245
Complexe	14	0,212	0,500	0,298	0,280
<i>Modes d'expression</i>					
Comportementale	36	0,278	0,139	0,185	0,159
Désignée	55	0,429	0,327	0,371	0,330
Montrée	300	0,481	0,463	0,472	0,152
Suggérée	54	0,158	0,056	0,082	0,048
<i>Catégories émotionnelles</i>					
Admiration	0	0,000	0,000	0,000	–
Autre	62	0,106	0,242	0,148	0,042
Colère	289	0,492	0,429	0,458	0,173
Culpabilité	3	0,000	0,000	0,000	0,000
Dégoût	80	0,000	0,000	0,000	0,000
Embarras	2	0,071	1,000	0,133	0,129
Fierté	3	0,750	1,000	0,857	0,857
Jalousie	6	0,000	0,000	0,000	0,000
Joie	30	0,423	0,367	0,393	0,370
Peur	4	0,154	0,500	0,235	0,229
Surprise	5	0,333	0,400	0,364	0,359
Tristesse	14	0,115	0,214	0,150	0,130

TABLE 3 – Performances détaillées d'EMOTYC sur le corpus *CyberAggAdo* global avec contexte. Le support correspond au nombre d'occurrences positives dans l'annotation de référence.

Les performances observées sur *CyberAggAdo* sont nettement inférieures à celles obtenues sur *TextToKids*. La présence d'une émotion reste la tâche la plus robuste, avec une F1 de 0,660, tandis que l'identification des modes d'expression et des catégories émotionnelles obtient des scores plus faibles : le mode *suggéré* atteint 0,082 de F1 et la colère, très représentée dans le corpus, atteint 0,458 de F1. Ces écarts décrivent une sensibilité aux différences de domaine entre des textes jeunesse édités et des messages numériques conversationnels.¹

Dans ce contexte, l'extraction automatique des signaux émotionnels conserve un intérêt analytique. Dragos et al. [6] montrent que la colère domine les corpus étudiés, mais que sa densité varie selon les types de contenus : elle représente 61,5 % des émotions dans les textes haineux, contre 15,6 % dans les contenus non haineux. À l'inverse, l'admiration apparaît davantage dans les contenus non haineux. Ces résultats indiquent que le profil émotionnel peut contribuer à caractériser les contenus toxiques et à compléter les approches strictement binaires de la toxicité en ligne [6, 1].

0.4 Résultats descriptifs sur CyberAggAdo

Les analyses statistiques réalisées sur les annotations de *CyberAggAdo* indiquent que certaines émotions et certains modes sont associés au degré d'agressivité annoté. Dans le rapport [hate_emotions_correlation_report.md](#), la colère et le dégoût sont plus fréquents dans les messages d'agressivité ouverte (OAG) que dans les messages non agressifs ou couverts. Le rapport [hate_modes_correlation_report.md](#) montre de son côté que le mode *Montrée* est le mode le plus associé à l'agressivité ouverte.

Ces observations ne se substituent pas à une annotation manuelle ni à une évaluation de modèle. Elles fournissent plutôt un ensemble d'indices descriptifs permettant de relier les émotions, les modes d'expression, les rôles interactionnels et les catégories d'agressivité déjà présentes dans le corpus. Elles justifient l'intérêt d'articuler plusieurs niveaux d'analyse : lexique émotionnel, marqueurs linguistiques, annotations conversationnelles et sorties de modèles.

1. Les analyses complémentaires sont documentées dans [Eval-EMOTYC/results/rapport_performances.md](#) et dans les sorties de [EMOTYC/experimentations/error_analysis.py](#). Elles relèvent notamment un exact match de 34,6 % sur les 19 labels dans l'évaluation détaillée avec contexte, 80 occurrences gold de *Dégoût* sans prédiction positive au seuil 0,5, ainsi que des incohérences structurelles entre labels d'émotion, de mode et de niveau. La relance sans contexte avec seuils optimisés produit aussi des sorties dans [EMOTYC/experimentations/error_analysis_results/](#), dont des analyses de calibration, de densité de labels, de longueur, de variables conversationnelles, de Random Forest/SHAP et de règles d'association.

Perspectives

Plusieurs prolongements peuvent être envisagés à partir des ressources produites. Une première piste consiste à mieux distinguer les configurations d'évaluation d'EMOTYC : avec ou sans contexte, seuil fixe ou seuil calibré, corpus continu ou échantillon non contigu. Cette distinction est importante car le contexte immédiat n'a pas le même statut dans un texte continu de *TextToKids* et dans une conversation de cyberagression où les messages adjacents peuvent changer de locuteur, de cible ou d'intention.

Une deuxième piste consiste à appliquer un post-traitement logique aux sorties multi-labels. Lorsqu'une catégorie émotionnelle est prédite, le label global d'émotion devrait être cohérent avec cette prédiction ; de même, les labels *Base* et *Complexe* peuvent être dérivés des catégories émotionnelles plutôt que prédits indépendamment. Cette piste est documentée dans le rapport [rapport_performances.md](#) et dans les sorties structurées de [error_analysis_results/structured/](#).

Une troisième piste concerne la normalisation contrôlée du langage numérique : abréviations, argot, allongements graphiques, fautes fréquentes et formes propres aux interactions adolescentes. Cette normalisation doit rester prudente, car certaines graphies non standard sont aussi des indices expressifs. Les scripts de [ExpressionEmotionnelle](#) offrent un point de départ pour relier ces formes aux marqueurs émotionnels, au lexique et aux annotations de mode.

Enfin, les variables déjà présentes dans *CyberAggAdo*, telles que `ROLE`, `TARGET`, `HATE`, `INTENTION` ou `SENTIMENT`, peuvent être utilisées comme variables d'analyse ou comme informations complémentaires dans de futures expériences. L'objectif serait de mieux décrire la relation entre émotion, agressivité, cible et position interactionnelle, sans réduire la détection du cyberharcèlement à une simple classification binaire.

Références

- [1] D. Battistelli, F. Benamara et V. Patti, *Introduction to the Special Issue of the TAL Journal on Abusive Language : Linguistic Resources, Methods and Applications*, Traitement Automatique des Langues, 65 (3), pp. 7–20 (2025).
- [2] V. Dragos et Y. Constable, *Comparison of Classification Techniques for Extremism Detection in French Social Media*, Dans *2023 26th International Conference on Information Fusion (FUSION)*, pp. 1–6. IEEE (2023).
- [3] A. Etienne, *Analyse automatique des émotions dans les textes : contributions théoriques et applicatives dans le cadre de l'étude de la complexité des textes pour enfants*, Thèse de doctorat, Université de Nanterre-Paris X (2023).
- [4] V. Dragos, D. Battistelli, A. Etienne et Y. Constable, *Angry or sad ? emotion annotation for extremist content characterisation*, Dans *Proceedings of the Thirteenth Language Resources and Evaluation Conference*, pp. 193–201 (2022).
- [5] A. Étienne, D. Battistelli et G. Lecorvé, *Emotion Identification for French in Written Texts : Considering their Modes of Expression as a Step Towards Text Complexity Analysis* (2024).
- [6] V. Dragos, D. Battistelli, F. Sow et A. Etienne, *Exploring the Emotional Dimension of French Online Toxic Content*, Dans *Proceedings of the 2024 Joint International Conference on Computational Linguistics, Language Resources and Evaluation (LREC-COLING 2024)*, pp. 6945–6954 (2024).