

# Leveraging linguistic annotations to improve automatic detection of online content

Gwendal Tsang

Valentina Dragos  
Delphine Battistelli



# Sommaire

---

- ❶ Problématique et contexte
- ❷ Les corpus utilisés
- ❸ Méthodes
- ❹ Résultats
- ❺ Perspectives

# 1. Problématique et contexte

---

Les annotations linguistiques et émotionnelles peuvent-elles améliorer ou éclairer l'analyse et la détection des conversations de cyberharcèlement ?

## 2. Les corpus utilisés


## 2.1 Schéma d'annotation émotionnelle

---

- Les corpus sont représentés au niveau phrastique par un vecteur multi-label.
- Les 12 colonnes émotionnelles sont : Admiration, Autre, Colère, Culpabilité, Dégoût, Embarras, Fierté, Jalousie, Joie, Peur, Surprise et Tristesse.
- Les proportions ci-dessous sont calculées sur les activations positives de ces 12 colonnes.
- Une phrase pouvant porter plusieurs émotions, le dénominateur est le nombre total d'activations émotionnelles, et non le nombre de phrases.

## 2.2 Distributions des émotions dans les corpus


Corpus EmoTextToKids



Corpus de tweets




extrémiste



non extrémiste

Corpus de cyberharcèlement



Références : EmoTextToKids, Etienne (2023) ; tweets, Dragos et al. (2022) ; cyberharcèlement, Ollagnier et al. (2024).

## 2.3 Taille des corpus

---

| Référence               | Corpus                 | Taille |
|-------------------------|------------------------|--------|
| Etienne (2023)          | EmoTextToKids          | 27 911 |
| Dragos et al. (2022)    | Textes extrémistes     | 1 129  |
| Dragos et al. (2022)    | Textes non-extrémistes | 599    |
| Annotations CyberAggAdo | CyberAggAdo            | 781    |

## 2.4 Proportions émotionnelles extraites des XLSX

---

| Émotion     | EmoTextToKids |        | CyberAggAdo |        |
|-------------|---------------|--------|-------------|--------|
|             | n             | %      | n           | %      |
| Admiration  | 211           | 3,2 %  | 0           | 0,0 %  |
| Autre       | 1270          | 19,4 % | 62          | 12,4 % |
| Colère      | 1180          | 18,1 % | 289         | 58,0 % |
| Culpabilité | 19            | 0,3 %  | 3           | 0,6 %  |
| Dégoût      | 52            | 0,8 %  | 80          | 16,1 % |
| Embarras    | 162           | 2,5 %  | 2           | 0,4 %  |
| Fierté      | 202           | 3,1 %  | 3           | 0,6 %  |
| Jalousie    | 7             | 0,1 %  | 6           | 1,2 %  |
| Joie        | 888           | 13,6 % | 30          | 6,0 %  |
| Peur        | 1047          | 16,0 % | 4           | 0,8 %  |
| Surprise    | 824           | 12,6 % | 5           | 1,0 %  |
| Tristesse   | 673           | 10,3 % | 14          | 2,8 %  |

EmoTextToKids : 27 911 unités textuelles, 6 535 émotionnels. CyberAggAdo : 781 unités textuelles, 498 activations émotionnels.



## 2.5 Annotations du corpus CyberAggAdoLarge utilisées

---

- EMOTION** émotion repérée dans l'énoncé : colère, dégoût, joie, tristesse, etc.
- MODE** mode d'expression de l'émotion : suggérée, montrée, comportementale ou désignée.
- ROLE** de l'autre : victim, bully, bully\_support, victim\_support ou conciliator.
- TARGET** rôle de la cible du message.
- HATE** degré d'agressivité du message : ouverte, couverte ou absente.
- VAB** type de violence verbale : blâme, dénigrement, insulte, menace ou autre.
- INT** intention du message : attaquer, défendre, apaiser, encourager, etc.
- CTX** contexte interactionnel dans lequel l'énoncé répond ou s'inscrit.

## 2.6 Signification des étiquettes

---

### ROLE / TARGET

**bully** personne qui initie le harcèlement.

**victim** personne harcelée.

**bully\_support** personnes qui aident le harceleur.

**victim\_support** personnes qui aident la victime.

**conciliator** personnes qui cherchent à médiatiser le désaccord.

### HATE

**OAG** agressivité ouverte : hostilité explicite, menace, insulte ou haine directe.


**CAG** agressivité couverte : agressivité masquée, indirecte ou implicite.

**NAG** non agressif : absence de menace, insulte ou intimidation.


### 3. Méthodes

### 3.1 Qu'est-ce qu'EMOTYC ?

---



## 3.2 Méthodologie utilisée pour les tests de performance



### 3.3 Métriques utilisées

---

La précision mesure la fiabilité des prédictions positives :

$$\text{Precision} = \frac{TP}{TP + FP}$$

Le rappel mesure la capacité du modèle à retrouver les instances réellement positives :


$$\text{Recall} = \frac{TP}{TP + FN}$$

## 3.4 Interpréter les baisses de performance

---

- Une baisse de précision suggère que certains indices lexicaux ou contextuels valides dans TTK deviennent trompeurs dans CyberAggAdoLarge.
- Une baisse de rappel suggère que l'émotion concernée est exprimée dans CyberAggAdoLarge par des formes lexicales, discursives ou contextuelles différentes de celles apprises sur TTK. EMOTYC n'ayant jamais vu ces formes, il ne les détecte pas ou les associe à tort à un autre label émotionnel.

## 3.5 Classifieurs linéaires utilisés





## 4. Résultats

## 4.1.2 Plus fortes corrélations pairwise

---

### Top 1-5

- $\rho(\text{EMOTION} = \text{Colère}, \text{MODE} = \text{Montrée}) = 0.75$   
 $p < 0.001, n_{\cap} = 249$
- $\rho(\text{EMOTION} = \text{Joie}, \text{MODE} = \text{Désignée}) = 0.36$   
 $p < 0.001, n_{\cap} = 16$
- $\rho(\text{MODE} = \text{Montrée}, \text{HATE} = \text{OAG}) = 0.33$   
 $p < 0.001, n_{\cap} = 226$
- $\rho(\text{EMOTION} = \text{Dégoût}, \text{MODE} = \text{Montrée}) = 0.33$   
 $p < 0.001, n_{\cap} = 69$
- $\rho(\text{EMOTION} = \text{Jalousie}, \text{MODE} = \text{Désignée}) = 0.32$   
 $p < 0.001, n_{\cap} = 6$

### Top 6-10

- $\rho(\text{EMOTION} = \text{Dégoût}, \text{VAB} = \text{DNG}) = 0.30$   
 $p < 0.001, n_{\cap} = 35$
- $\rho(\text{EMOTION} = \text{Dégoût}, \text{VAB} = \text{OTH}) = -0.28$   
 $p < 0.001, n_{\cap} = 23$
- $\rho(\text{EMOTION} = \text{Tristesse}, \text{MODE} = \text{Suggérée}) = 0.27$   
 $p < 0.001, n_{\cap} = 8$
- $\rho(\text{EMOTION} = \text{Colère}, \text{TARGET} = \text{victim}) = -0.27$   
 $p < 0.001, n_{\cap} = 60$
- $\rho(\text{EMOTION} = \text{Colère}, \text{HATE} = \text{OAG}) = 0.26$   
 $p < 0.001, n_{\cap} = 207$

## 4.1.3 Plus fortes associations globales

---

### Top 1-5

- $\chi^2(\text{HATE}, \text{MODE} = \text{Montrée}) = 83.92$   
 $p < 0.001$
- $\chi^2(\text{INT}, \text{EMOTION} = \text{Colère}) = 72.93$   
 $p < 0.001$
- $\chi^2(\text{VAB}, \text{EMOTION} = \text{Dégoût}) = 71.21$   
 $p < 0.001$
- $\chi^2(\text{INT}, \text{MODE} = \text{Montrée}) = 68.60$   
 $p < 0.001$
- $\chi^2(\text{HATE}, \text{EMOTION} = \text{Colère}) = 55.13$   
 $p < 0.001$

### Top 6-10

- $\chi^2(\text{TARGET}, \text{EMOTION} = \text{Colère}) = 52.89$   
 $p < 0.001$
- $\chi^2(\text{HATE}, \text{EMOTION} = \text{Dégoût}) = 51.78$   
 $p < 0.001$
- $\chi^2(\text{INT}, \text{EMOTION} = \text{Dégoût}) = 50.45$   
 $p < 0.001$
- $\chi^2(\text{TARGET}, \text{EMOTION} = \text{Dégoût}) = 36.91$   
 $p < 0.001$
- $\chi^2(\text{CTX}, \text{EMOTION} = \text{Embarras}) = 35.50$   
 $p < 0.001$

## 4.1.4 Lecture rapide des corrélations

---

- Le signal pairwise maximal devient  $\rho(\text{EMOTION} = \text{Colère}, \text{MODE} = \text{Montrée}) = 0.75$ .
- Les autres liens émotion-mode les plus visibles sont Joie–Désignée, Dégoût–Montrée, Jalousie–Désignée et Tristesse–Suggérée.
- **Dégoût** concentre aussi des liens marqués avec la violence verbale : DNG positif et OTH négatif.
- **Colère** reste associée à HATE :OAG et INT :DFN, mais inversement à HATE :NAG et TARGET :victim.

## 4.2.1 Performances EMOTYC

---

| Référence               | Corpus        | Précision | Rappel | F1   |
|-------------------------|---------------|-----------|--------|------|
| Etienne (2023)          | EmoTextToKids | 0,90      | 0,89   | 0,90 |
| Dragos et al. (2022)    | Extrémisme    | 0,80      | 0,25   | 0,38 |
| Annotations CyberAggAdo | CyberAggAdo   | 0,49      | 0,46   | 0,47 |

Pour EmoTextToKids et CyberAggAdo, les métriques sont micro-moyennées sur les 19 labels EMOTYC à partir des JSON de résultats.

## 4.2.2 Ce que mesure la heatmap

---

$$\Delta_m(\ell) = m_{\text{TextToKids}}(\ell) - m_{\text{CyberAggAdo}}(\ell)$$

- Les colonnes comparent  $F_1$ , la précision et le rappel, label par label.
- La couleur encode  $|\Delta|$  : vert clair si les performances sont proches, orange/rouge si l'écart est fort.
- Une valeur positive signifie que le modèle performe mieux sur TextToKids que sur CyberAggAdo.

| Corpus      | Unités textuelles |
|-------------|-------------------|
| TextToKids  | 27 911            |
| CyberAggAdo | 781               |

Configuration : template avec contexte, seuil 0.5, comparaison directe des résumés JSON.

## 4.2.3 Heatmaps

---

| Label   | Cyber | $\Delta F_1$ | $\Delta P$ | $\Delta R$ |
|---------|-------|--------------|------------|------------|
| Émo     | 398   | +0.27        | +0.31      | +0.23      |
| Base    | 363   | +0.37        | +0.29      | +0.43      |
| Montrée | 300   | +0.41        | +0.42      | +0.41      |
| Colère  | 289   | +0.46        | +0.42      | +0.49      |
| Autre   | 62    | +0.76        | +0.78      | +0.68      |

Lecture : 4 labels les plus représentés dans CyberAggAdoLarge, plus le plus fort décrochage robuste.  $\Delta > 0$  indique une performance supérieure sur TextToKids ; la couleur indique l'amplitude, pas le sens.

## 4.2.5 Labels concentrant le décrochage

| Label    | Cyber | TTK   | $\Delta F_1$ | $\Delta P$ | $\Delta R$ |
|----------|-------|-------|--------------|------------|------------|
| Autre    | 62    | 1 270 | +0.76        | +0.78      | +0.68      |
| Suggérée | 54    | 1 909 | +0.73        | +0.67      | +0.74      |
| Désignée | 55    | 1 499 | +0.56        | +0.50      | +0.60      |
| Colère   | 289   | 1 180 | +0.46        | +0.42      | +0.49      |
| Montrée  | 300   | 971   | +0.41        | +0.42      | +0.41      |
| Base     | 363   | 4 133 | +0.37        | +0.29      | +0.43      |

- Le mode *Suggérée* décroche fortement : les indices contextuels appris sur TextToKids transfèrent mal vers les messages de cyberharcèlement.
- *Autre* est le plus grand écart parmi les labels avec au moins 50 occurrences positives dans CyberAggAdoLarge.
- *Colère* et *Montrée* restent suffisamment représentés pour signaler une vraie difficulté, pas seulement un bruit d'effectif.



## 4.2.6 Points de vigilance


---

- Les labels très rares dans CyberAggAdoLarge doivent être interprétés avec prudence : *Admiration* a 0 occurrence positive, *Embarras* 2, *Fierté* 3, *Peur* 4.
- La couleur ne distingue pas le signe : une case claire peut aussi correspondre à une absence de cas suffisants pour comparer.
- La heatmap sert surtout à localiser les zones de non-transférabilité ; l'analyse qualitative des erreurs reste nécessaire pour expliquer les mécanismes.

Conclusion : EMOTYC apprend bien le domaine TextToKids, mais les formes discursives de CyberAggAdoLarge changent assez pour dégrader la généralisation, notamment sur les modes d'expression et certains labels émotionnels.

## 4.3 Comparaison classifieurs linéaires / EMOTYC

---



## 5. Perspectives

---

- ❶ **Adapter EMOTYC aux messages numériques.** Fine-tuning sur un corpus mixte intégrant abréviations SMS, argot adolescent, emojis et ponctuation expressive, pour couvrir les formes d'expression absentes du registre littéraire jeunesse.
- ❷ **Exploiter les annotations *mépris / haine* de TextToKids.** Créer un label dédié *MéprisHaine* à partir des 344 lignes XLSX et 147 unités Glozz déjà annotées, afin de réduire l'hétérogénéité du label *Autre* et d'affiner la détection en contexte de cyberharcèlement.
- ❸ **Modéliser les transitions émotionnelles dans CyberAggAdo.** Exploiter les couples (ROLE, TARGET) pour construire des matrices de transition  $\text{émotion}_t \rightarrow \text{émotion}_{t+1}$  et identifier des patterns prédictifs d'escalade ou de désescalade du harcèlement (cf. Ide & Kawahara, 2022).

## A.1 Lecture de la notation

---

- $\rho(X = a, Y = b)$  reprend le coefficient Phi pour une paire de variables binaires.
- $\chi^2(F, X = a)$  résume le test global entre une famille catégorielle  $F$  et une variable binaire.
- Les p-values très petites sont ramenées à des seuils :  $p < 0.05$ ,  $p < 0.01$ ,  $p < 0.005$  ou  $p < 0.001$ .
- $n_{\cap}$  indique le nombre de cooccurrences de la paire.

## A.2 Émotions × modes d'expression

---

### Top pairwise : $\rho$

- $\rho(\text{EMOTION} = \text{Colère}, \text{MODE} = \text{Montrée}) = 0.75$   
 $p < 0.001, n_{\cap} = 249$
- $\rho(\text{EMOTION} = \text{Joie}, \text{MODE} = \text{Désignée}) = 0.36$   
 $p < 0.001, n_{\cap} = 16$
- $\rho(\text{EMOTION} = \text{Dégoût}, \text{MODE} = \text{Montrée}) = 0.33$   
 $p < 0.001, n_{\cap} = 69$
- $\rho(\text{EMOTION} = \text{Jalousie}, \text{MODE} = \text{Désignée}) = 0.32$   
 $p < 0.001, n_{\cap} = 6$
- $\rho(\text{EMOTION} = \text{Tristesse}, \text{MODE} = \text{Suggérée}) = 0.27$   
 $p < 0.001, n_{\cap} = 8$

### Lecture

- La corrélation Colère–Montrée domine nettement tous les autres résultats.
- Dégoût suit le même axe expressif que Colère, mais avec un effet plus modéré.
- Joie et Jalousie ressortent avec le mode Désignée ; Jalousie reste portée par un petit effectif.
- Tristesse apparaît surtout du côté Suggérée dans ce top.

## A.3 Émotions × haine / agressivité

---

### Pairwise : $\rho$

- $\rho(\text{EMOTION} = \text{Colère}, \text{HATE} = \text{OAG}) = 0.26$   
 $p < 0.001, n_{\cap} = 207$
- $\rho(\text{EMOTION} = \text{Dégoût}, \text{HATE} = \text{OAG}) = 0.26$   
 $p < 0.001, n_{\cap} = 74$
- $\rho(\text{EMOTION} = \text{Dégoût}, \text{HATE} = \text{NAG}) = -0.21$   
 $p < 0.001, n_{\cap} = 3$
- $\rho(\text{EMOTION} = \text{Colère}, \text{HATE} = \text{NAG}) = -0.17$   
 $p < 0.001, n_{\cap} = 66$
- $\rho(\text{EMOTION} = \text{Colère}, \text{HATE} = \text{CAG}) = -0.15$   
 $p < 0.001, n_{\cap} = 16$

### Global : $\chi^2$

- $\chi^2(\text{HATE}, \text{EMOTION} = \text{Colère}) = 55.13$   
 $p < 0.001$
- $\chi^2(\text{HATE}, \text{EMOTION} = \text{Dégoût}) = 51.78$   
 $p < 0.001$
- $\chi^2(\text{HATE}, \text{EMOTION} = \text{Autre}) = 7.54$   
 $p < 0.05$
- $\chi^2(\text{HATE}, \text{EMOTION} = \text{Culpabilité}) = 6.00$   
 $p = 0.05$
- $\chi^2(\text{HATE}, \text{EMOTION} = \text{Fierté}) = 6.00$   
 $p = 0.05$

## A.4 Émotions × intention

---

### Pairwise : $\rho$

- $\rho(\text{EMOTION} = \text{Colère}, \text{INT} = \text{DFN}) = 0.25$   
 $p < 0.001, n_{\cap} = 127$
- $\rho(\text{EMOTION} = \text{Colère}, \text{INT} = \text{OTH}) = -0.18$   
 $p < 0.001, n_{\cap} = 18$
- $\rho(\text{EMOTION} = \text{Fierté}, \text{INT} = \text{CNS}) = 0.16$   
 $p < 0.001, n_{\cap} = 2$
- $\rho(\text{EMOTION} = \text{Dégoût}, \text{INT} = \text{AIN}) = 0.16$   
 $p < 0.001, n_{\cap} = 15$
- $\rho(\text{EMOTION} = \text{Culpabilité}, \text{INT} = \text{OTH}) = 0.15$   
 $p < 0.001, n_{\cap} = 3$

### Global : $\chi^2$

- $\chi^2(\text{INT}, \text{EMOTION} = \text{Colère}) = 72.93$   
 $p < 0.001$
- $\chi^2(\text{INT}, \text{EMOTION} = \text{Dégoût}) = 50.45$   
 $p < 0.001$
- $\chi^2(\text{INT}, \text{EMOTION} = \text{Fierté}) = 22.55$   
 $p < 0.005$
- $\chi^2(\text{INT}, \text{EMOTION} = \text{Culpabilité}) = 17.99$   
 $p < 0.05$
- $\chi^2(\text{INT}, \text{EMOTION} = \text{Tristesse}) = 14.26$   
 $p = 0.05$

## A.5 Émotions × cible

---

### Pairwise : $\rho$

- $\rho(\text{EMOTION} = \text{Colère}, \text{TARGET} = \text{victim}) = -0.27$   
 $p < 0.001, n_{\cap} = 60$
- $\rho(\text{EMOTION} = \text{Dégoût}, \text{TARGET} = \text{victim}) = 0.25$   
 $p < 0.001, n_{\cap} = 55$
- $\rho(\text{EMOTION} = \text{Jalousie}, \text{TARGET} = \text{bully\_support}) = 0.18$   
 $p < 0.001, n_{\cap} = 4$
- $\rho(\text{EMOTION} = \text{Colère}, \text{TARGET} = \text{bully}) = 0.17$   
 $p < 0.001, n_{\cap} = 70$
- $\rho(\text{EMOTION} = \text{Colère}, \text{TARGET} = \text{bully\_support}) = 0.16$   
 $p < 0.001, n_{\cap} = 60$

### Global : $\chi^2$

- $\chi^2(\text{TARGET}, \text{EMOTION} = \text{Colère}) = 52.89$   
 $p < 0.001$
- $\chi^2(\text{TARGET}, \text{EMOTION} = \text{Dégoût}) = 36.91$   
 $p < 0.001$
- $\chi^2(\text{TARGET}, \text{EMOTION} = \text{Jalousie}) = 21.17$   
 $p < 0.05$
- $\chi^2(\text{TARGET}, \text{EMOTION} = \text{Embarras}) = 13.24$   
 $p = 0.15$
- $\chi^2(\text{TARGET}, \text{EMOTION} = \text{Autre}) = 10.00$   
 $p = 0.35$



## A.6 Émotions × rôle

---

### Pairwise : $\rho$

- $\rho(\text{EMOTION} = \text{Dégoût}, \text{ROLE} = \text{bully}) = 0.14$   
 $p < 0.001, n_{\cap} = 23$
- $\rho(\text{EMOTION} = \text{Colère}, \text{ROLE} = \text{bully\_support}) = -0.14$   
 $p < 0.001, n_{\cap} = 74$
- $\rho(\text{EMOTION} = \text{Tristesse}, \text{ROLE} = \text{victim}) = 0.13$   
 $p < 0.001, n_{\cap} = 6$
- $\rho(\text{EMOTION} = \text{Colère}, \text{ROLE} = \text{victim}) = 0.13$   
 $p < 0.001, n_{\cap} = 48$
- $\rho(\text{EMOTION} = \text{Dégoût}, \text{ROLE} = \text{conciliator}) = -0.13$   
 $p < 0.001, n_{\cap} = 4$

### Global : $\chi^2$

- $\chi^2(\text{ROLE}, \text{EMOTION} = \text{Dégoût}) = 34.60$   
 $p < 0.001$
- $\chi^2(\text{ROLE}, \text{EMOTION} = \text{Colère}) = 25.67$   
 $p < 0.001$
- $\chi^2(\text{ROLE}, \text{EMOTION} = \text{Tristesse}) = 17.71$   
 $p < 0.005$
- $\chi^2(\text{ROLE}, \text{EMOTION} = \text{Autre}) = 15.47$   
 $p < 0.005$
- $\chi^2(\text{ROLE}, \text{EMOTION} = \text{Joie}) = 9.70$   
 $p = 0.05$

## A.7 Émotions × contexte

---

### Pairwise : $\rho$

- $\rho(\text{EMOTION} = \text{Embarras}, \text{CTX} = \text{CR}) = 0.23$   
 $p < 0.005, n_{\cap} = 1$
- $\rho(\text{EMOTION} = \text{Colère}, \text{CTX} = \text{ATK}) = 0.16$   
 $p < 0.001, n_{\cap} = 128$
- $\rho(\text{EMOTION} = \text{Culpabilité}, \text{CTX} = \text{CR}) = 0.16$   
 $p = 0.05, n_{\cap} = 1$
- $\rho(\text{EMOTION} = \text{Surprise}, \text{CTX} = \text{EMP}) = 0.13$   
 $p = 0.12, n_{\cap} = 1$
- $\rho(\text{EMOTION} = \text{Colère}, \text{CTX} = \text{OTH}) = -0.12$   
 $p < 0.005, n_{\cap} = 18$

### Global : $\chi^2$

- $\chi^2(\text{CTX}, \text{EMOTION} = \text{Embarras}) = 35.50$   
 $p < 0.001$
- $\chi^2(\text{CTX}, \text{EMOTION} = \text{Colère}) = 23.36$   
 $p < 0.005$
- $\chi^2(\text{CTX}, \text{EMOTION} = \text{Culpabilité}) = 20.44$   
 $p < 0.005$
- $\chi^2(\text{CTX}, \text{EMOTION} = \text{Surprise}) = 18.15$   
 $p < 0.05$
- $\chi^2(\text{CTX}, \text{EMOTION} = \text{Dégoût}) = 12.67$   
 $p = 0.08$

## A.8 Modes d'expression $\times$ haine / agressivité

---

### Pairwise : $\rho$

- $\rho(\text{MODE} = \text{Montrée}, \text{HATE} = \text{OAG}) = 0.33$   
 $p < 0.001, n_{\cap} = 226$
- $\rho(\text{MODE} = \text{Montrée}, \text{HATE} = \text{NAG}) = -0.26$   
 $p < 0.001, n_{\cap} = 54$
- $\rho(\text{MODE} = \text{Montrée}, \text{HATE} = \text{CAG}) = -0.13$   
 $p < 0.001, n_{\cap} = 20$
- $\rho(\text{MODE} = \text{Désignée}, \text{HATE} = \text{CAG}) = -0.07$   
 $p = 0.08, n_{\cap} = 2$
- $\rho(\text{MODE} = \text{Désignée}, \text{HATE} = \text{OAG}) = 0.07$   
 $p = 0.07, n_{\cap} = 37$

### Global : $\chi^2$

- $\chi^2(\text{HATE}, \text{MODE} = \text{Montrée}) = 83.92$   
 $p < 0.001$
- $\chi^2(\text{HATE}, \text{MODE} = \text{Désignée}) = 5.45$   
 $p = 0.07$
- $\chi^2(\text{HATE}, \text{MODE} = \text{Comportementale}) = 3.07$   
 $p = 0.22$
- $\chi^2(\text{HATE}, \text{MODE} = \text{Suggérée}) = 2.24$   
 $p = 0.33$

## A.9 Modes d'expression $\times$ violence verbale

---

### Pairwise : $\rho$

- $\rho(\text{MODE} = \text{Comportementale}, \text{VAB} = \text{THR}) = 0.17$   
 $p < 0.001, n_{\cap} = 6$
- $\rho(\text{MODE} = \text{Montrée}, \text{VAB} = \text{NCG}) = 0.13$   
 $p < 0.005, n_{\cap} = 41$
- $\rho(\text{MODE} = \text{Désignée}, \text{VAB} = \text{DNG}) = 0.09$   
 $p = 0.05, n_{\cap} = 12$
- $\rho(\text{MODE} = \text{Désignée}, \text{VAB} = \text{NCG}) = -0.08$   
 $p = 0.10, n_{\cap} = 1$
- $\rho(\text{MODE} = \text{Comportementale}, \text{VAB} = \text{NCG}) = -0.08$   
 $p = 0.15, n_{\cap} = 0$

### Global : $\chi^2$

- $\chi^2(\text{VAB}, \text{MODE} = \text{Comportementale}) = 17.60$   
 $p < 0.005$
- $\chi^2(\text{VAB}, \text{MODE} = \text{Montrée}) = 12.44$   
 $p < 0.05$
- $\chi^2(\text{VAB}, \text{MODE} = \text{Désignée}) = 10.04$   
 $p < 0.05$
- $\chi^2(\text{VAB}, \text{MODE} = \text{Suggérée}) = 4.37$   
 $p = 0.36$

## A.10 Modes d'expression $\times$ intention

---

### Pairwise : $\rho$

- $\rho(\text{MODE} = \text{Montrée}, \text{INT} = \text{OTH}) = -0.21$   
 $p < 0.001, n_{\cap} = 15$
- $\rho(\text{MODE} = \text{Montrée}, \text{INT} = \text{DFN}) = 0.21$   
 $p < 0.001, n_{\cap} = 123$
- $\rho(\text{MODE} = \text{Montrée}, \text{INT} = \text{EMP}) = -0.11$   
 $p < 0.01, n_{\cap} = 2$
- $\rho(\text{MODE} = \text{Suggérée}, \text{INT} = \text{EMP}) = 0.07$   
 $p = 0.11, n_{\cap} = 4$
- $\rho(\text{MODE} = \text{Désignée}, \text{INT} = \text{DFN}) = -0.07$   
 $p = 0.09, n_{\cap} = 10$

### Global : $\chi^2$

- $\chi^2(\text{INT}, \text{MODE} = \text{Montrée}) = 68.60$   
 $p < 0.001$
- $\chi^2(\text{INT}, \text{MODE} = \text{Suggérée}) = 7.98$   
 $p = 0.33$
- $\chi^2(\text{INT}, \text{MODE} = \text{Désignée}) = 6.77$   
 $p = 0.45$
- $\chi^2(\text{INT}, \text{MODE} = \text{Comportementale}) = 5.54$   
 $p = 0.59$

## A.11 Modes d'expression × cible

---

### Pairwise : $\rho$

- $\rho(\text{MODE} = \text{Montrée}, \text{TARGET} = \text{victim}) = -0.17$   
 $p < 0.001, n_{\cap} = 82$
- $\rho(\text{MODE} = \text{Désignée}, \text{TARGET} = \text{victim}) = 0.13$   
 $p < 0.01, n_{\cap} = 25$
- $\rho(\text{MODE} = \text{Montrée}, \text{TARGET} = \text{bully}) = 0.11$   
 $p < 0.05, n_{\cap} = 70$
- $\rho(\text{MODE} = \text{Montrée}, \text{TARGET} = \text{bully\_support}) = 0.11$   
 $p < 0.05, n_{\cap} = 60$
- $\rho(\text{MODE} = \text{Désignée}, \text{TARGET} = \text{bully}) = -0.09$   
 $p = 0.07, n_{\cap} = 4$

### Global : $\chi^2$

- $\chi^2(\text{TARGET}, \text{MODE} = \text{Montrée}) = 25.56$   
 $p < 0.005$
- $\chi^2(\text{TARGET}, \text{MODE} = \text{Désignée}) = 13.25$   
 $p = 0.15$
- $\chi^2(\text{TARGET}, \text{MODE} = \text{Suggérée}) = 6.66$   
 $p = 0.67$
- $\chi^2(\text{TARGET}, \text{MODE} = \text{Comportementale}) = 4.55$   
 $p = 0.87$

## A.12 Modes d'expression $\times$ rôle

---

### Pairwise : $\rho$

- $\rho(\text{MODE} = \text{Montrée}, \text{ROLE} = \text{victim}) = 0.09$   
 $p < 0.05, n_{\cap} = 45$
- $\rho(\text{MODE} = \text{Montrée}, \text{ROLE} = \text{conciliator}) = -0.08$   
 $p < 0.05, n_{\cap} = 48$
- $\rho(\text{MODE} = \text{Montrée}, \text{ROLE} = \text{bully\_support}) = -0.07$   
 $p = 0.06, n_{\cap} = 90$
- $\rho(\text{MODE} = \text{Désignée}, \text{ROLE} = \text{bully\_support}) = 0.07$   
 $p = 0.09, n_{\cap} = 25$
- $\rho(\text{MODE} = \text{Montrée}, \text{ROLE} = \text{bully}) = 0.06$   
 $p = 0.15, n_{\cap} = 50$

### Global : $\chi^2$

- $\chi^2(\text{ROLE}, \text{MODE} = \text{Montrée}) = 15.37$   
 $p < 0.005$
- $\chi^2(\text{ROLE}, \text{MODE} = \text{Désignée}) = 4.60$   
 $p = 0.33$
- $\chi^2(\text{ROLE}, \text{MODE} = \text{Comportementale}) = 3.21$   
 $p = 0.52$
- $\chi^2(\text{ROLE}, \text{MODE} = \text{Suggérée}) = 0.66$   
 $p = 0.96$

## A.13 Modes d'expression × contexte

---

### Pairwise : $\rho$

- $\rho(\text{MODE} = \text{Montrée}, \text{CTX} = \text{OTH}) = -0.13$   
 $p < 0.005, n_{\cap} = 18$
- $\rho(\text{MODE} = \text{Montrée}, \text{CTX} = \text{ATK}) = 0.12$   
 $p < 0.005, n_{\cap} = 127$
- $\rho(\text{MODE} = \text{Suggérée}, \text{CTX} = \text{CR}) = 0.07$   
 $p = 0.17, n_{\cap} = 3$
- $\rho(\text{MODE} = \text{Comportementale}, \text{CTX} = \text{ATK}) = 0.07$   
 $p = 0.11, n_{\cap} = 17$
- $\rho(\text{MODE} = \text{Désignée}, \text{CTX} = \text{CR}) = 0.07$   
 $p = 0.20, n_{\cap} = 3$

### Global : $\chi^2$

- $\chi^2(\text{CTX}, \text{MODE} = \text{Montrée}) = 19.34$   
 $p < 0.01$
- $\chi^2(\text{CTX}, \text{MODE} = \text{Comportementale}) = 9.08$   
 $p = 0.25$
- $\chi^2(\text{CTX}, \text{MODE} = \text{Désignée}) = 7.53$   
 $p = 0.38$
- $\chi^2(\text{CTX}, \text{MODE} = \text{Suggérée}) = 6.77$   
 $p = 0.45$



## A.14 Points d'attention sur les corrélations

---

- Le maximum identifié est  $|\rho| = 0.75$ , porté par Colère–Montrée.

# Références

---

- [1] Dragos, V., Battistelli, D., Etienne, A., and Constable, Y. (2022). *Angry or sad ? emotion annotation for extremist content characterisation*. Proceedings of the Thirteenth Language Resources and Evaluation Conference, 193–201.
- [2] Etienne, A. (2023). *Analyse automatique des émotions dans les textes : contributions théoriques et applicatives dans le cadre de l'étude de la complexité des textes pour enfants*. PhD thesis, Université de Nanterre-Paris X.
- [3] Dragos, V., and Constable, Y. (2023). *Comparison of Classification Techniques for Extremism Detection in French Social Media*. 2023 26th International Conference on Information Fusion (FUSION), 1–6. IEEE.
- [4] Dragos, V., Battistelli, D., Sow, F., and Etienne, A. (2024). *Exploring the Emotional Dimension of French Online Toxic Content*. Proceedings of the 2024 Joint International Conference on Computational Linguistics, Language Resources and Evaluation (LREC-COLING 2024), 6945–6954.
- [5] Étienne, A., Battistelli, D., and Lecorvé, G. (2024). *Emotion Identification for French in Written Texts : Considering their Modes of Expression as a Step Towards Text Complexity Analysis*. arXiv :2405.14385.
- [6] Battistelli, D., Benamara, F., and Patti, V. (2025). *Introduction to the Special Issue of the TAL Journal on Abusive Language : Linguistic Resources, Methods and Applications*. Traitement Automatique des Langues, 65(3), 7–20.
- [7] Ide, T., and Kawahara, D. (2022). *Building a Dialogue Corpus Annotated with Expressed and Experienced Emotions*. Proceedings of the Thirteenth Language Resources and Evaluation Conference (LREC 2022), 6474–6481.