

# Leveraging linguistic annotations to improve automatic detection of online content

Gwendal Tsang

Valentina Dragos  
Delphine Battistelli



- ❶ Problématique globale
- ❷ Le corpus CyberAggAdoLarge
- ❸ Tests du modèle EMOTYC
- ❹ Tests avec des classifieurs linéaires

# 1. Problématique globale

---

Les annotations linguistiques et émotionnelles peuvent-elles améliorer ou éclairer l'analyse et la détection des conversations de cyberharcèlement ?

## 2. Le corpus CyberAggAdoLarge

## 2.1.1 Annotations du corpus CyberAggAdo utilisées

---

**EMOTION** émotion repérée dans l'énoncé : colère, dégoût, joie, tristesse, etc.

**MODE** mode d'expression de l'émotion : suggérée, montrée, comportementale ou désignée.

**ROLE** de l'autre : victim, bully, bully\_support, victim\_support ou conciliator.

**TARGET** rôle de la cible du message.

**HATE** degré d'agressivité du message : ouverte, couverte ou absente.

**VAB** type de violence verbale : blâme, dénigrement, insulte, menace ou autre.

**INT** intention du message : attaquer, défendre, apaiser, encourager, etc.

**CTX** contexte interactionnel dans lequel l'énoncé répond ou s'inscrit.

## 2.1.2 Explication de la signification des étiquettes 1

---

### **ROLE / TARGET**

**bully** personne qui initie le harcèlement.

**victim** personne harcelée.

**bully\_support** personnes qui aident le harceleur.

**victim\_support** personnes qui aident la victime.

**conciliator** personnes qui cherchent à médiatiser le désaccord.

### **HATE**

**OAG** agressivité ouverte : hostilité explicite, menace, insulte ou haine directe.

**CAG** agressivité couverte : agressivité masquée, indirecte ou implicite.

**NAG** non agressif : absence de menace, insulte ou intimidation.

## 2.1.3 Explication de la signification des étiquettes 2

---

### VAB

- BLM** blâme : rendre la victime responsable de l'abus.
- DNG** dénigrement : remarques blessantes et non constructives.
- NCG** insultes ou name calling.
- THR** menace visant à effrayer ou contraindre.
- OTH** autre.

### INT / CTX

- ATK** attaque : agression délibérée, moquerie, exclusion ou discrédit.
- DFN** défense : réponse protectrice à une attaque.
- CNS** contre-discours non agressif contre un discours nuisible.
- AIN** incitation ou validation d'un message négatif.
- GSL** gaslighting : minimisation ou invalidation du vécu de la victime.
- EMP** empathie, compassion ou soutien.
- CR** résolution de conflit, médiation ou désescalade.
- OTH** intention peu claire, énoncé neutre ou fragmentaire.

## 2.2.1 Lecture de la notation

---

- $\rho(X = a, Y = b)$  reprend le coefficient Phi pour une paire de variables binaires.
- $\chi^2(F, X = a)$  résume le test global entre une famille catégorielle  $F$  et une variable binaire.
- Les p-values très petites sont ramenées à des seuils :  $p < 0.05$ ,  $p < 0.01$ ,  $p < 0.005$  ou  $p < 0.001$ .
- $n_{\cap}$  indique le nombre de cooccurrences de la paire.

## 2.2.2 Plus fortes corrélations pairwise

---

### Top 1-5

- $\rho(\text{EMOTION} = \text{Colère}, \text{MODE} = \text{Montrée}) = 0.75$   
 $p < 0.001, n_{\cap} = 249$
- $\rho(\text{EMOTION} = \text{Joie}, \text{MODE} = \text{Désignée}) = 0.36$   
 $p < 0.001, n_{\cap} = 16$
- $\rho(\text{MODE} = \text{Montrée}, \text{HATE} = \text{OAG}) = 0.33$   
 $p < 0.001, n_{\cap} = 226$
- $\rho(\text{EMOTION} = \text{Dégoût}, \text{MODE} = \text{Montrée}) = 0.33$   
 $p < 0.001, n_{\cap} = 69$
- $\rho(\text{EMOTION} = \text{Jalousie}, \text{MODE} = \text{Désignée}) = 0.32$   
 $p < 0.001, n_{\cap} = 6$

### Top 6-10

- $\rho(\text{EMOTION} = \text{Dégoût}, \text{VAB} = \text{DNG}) = 0.30$   
 $p < 0.001, n_{\cap} = 35$
- $\rho(\text{EMOTION} = \text{Dégoût}, \text{VAB} = \text{OTH}) = -0.28$   
 $p < 0.001, n_{\cap} = 23$
- $\rho(\text{EMOTION} = \text{Tristesse}, \text{MODE} = \text{Suggérée}) = 0.27$   
 $p < 0.001, n_{\cap} = 8$
- $\rho(\text{EMOTION} = \text{Colère}, \text{TARGET} = \text{victim}) = -0.27$   
 $p < 0.001, n_{\cap} = 60$
- $\rho(\text{EMOTION} = \text{Colère}, \text{HATE} = \text{OAG}) = 0.26$   
 $p < 0.001, n_{\cap} = 207$

## 2.2.3 Plus fortes associations globales

---

### Top 1-5

- $\chi^2(\text{HATE}, \text{MODE} = \text{Montrée}) = 83.92$   
 $p < 0.001$
- $\chi^2(\text{INT}, \text{EMOTION} = \text{Colère}) = 72.93$   
 $p < 0.001$
- $\chi^2(\text{VAB}, \text{EMOTION} = \text{Dégoût}) = 71.21$   
 $p < 0.001$
- $\chi^2(\text{INT}, \text{MODE} = \text{Montrée}) = 68.60$   
 $p < 0.001$
- $\chi^2(\text{HATE}, \text{EMOTION} = \text{Colère}) = 55.13$   
 $p < 0.001$

### Top 6-10

- $\chi^2(\text{TARGET}, \text{EMOTION} = \text{Colère}) = 52.89$   
 $p < 0.001$
- $\chi^2(\text{HATE}, \text{EMOTION} = \text{Dégoût}) = 51.78$   
 $p < 0.001$
- $\chi^2(\text{INT}, \text{EMOTION} = \text{Dégoût}) = 50.45$   
 $p < 0.001$
- $\chi^2(\text{TARGET}, \text{EMOTION} = \text{Dégoût}) = 36.91$   
 $p < 0.001$
- $\chi^2(\text{CTX}, \text{EMOTION} = \text{Embarras}) = 35.50$   
 $p < 0.001$

## 2.2.4 Lecture rapide des résultats

---

- Le signal pairwise maximal devient  $\rho(\text{EMOTION} = \text{Colère}, \text{MODE} = \text{Montrée}) = 0.75$ .
- Les autres liens émotion-mode les plus visibles sont Joie–Désignée, Dégoût–Montrée, Jalousie–Désignée et Tristesse–Suggérée.
- **Dégoût** concentre aussi des liens marqués avec la violence verbale : DNG positif et OTH négatif.
- **Colère** reste associée à HATE :OAG et INT :DFN, mais inversement à HATE :NAG et TARGET :victim.

## 2.2.5 Émotions × modes d'expression

---

### Top pairwise : $\rho$

- $\rho(\text{EMOTION} = \text{Colère}, \text{MODE} = \text{Montrée}) = 0.75$   
 $p < 0.001, n_{\cap} = 249$
- $\rho(\text{EMOTION} = \text{Joie}, \text{MODE} = \text{Désignée}) = 0.36$   
 $p < 0.001, n_{\cap} = 16$
- $\rho(\text{EMOTION} = \text{Dégoût}, \text{MODE} = \text{Montrée}) = 0.33$   
 $p < 0.001, n_{\cap} = 69$
- $\rho(\text{EMOTION} = \text{Jalousie}, \text{MODE} = \text{Désignée}) = 0.32$   
 $p < 0.001, n_{\cap} = 6$
- $\rho(\text{EMOTION} = \text{Tristesse}, \text{MODE} = \text{Suggérée}) = 0.27$   
 $p < 0.001, n_{\cap} = 8$

### Lecture

- La corrélation Colère–Montrée domine nettement tous les autres résultats.
- Dégoût suit le même axe expressif que Colère, mais avec un effet plus modéré.
- Joie et Jalousie ressortent avec le mode Désignée ; Jalousie reste portée par un petit effectif.
- Tristesse apparaît surtout du côté Suggérée dans ce top.

## 2.2.6 Émotions $\times$ haine / agressivité

---

### Pairwise : $\rho$

- $\rho(\text{EMOTION} = \text{Colère}, \text{HATE} = \text{OAG}) = 0.26$   
 $p < 0.001, n_{\cap} = 207$
- $\rho(\text{EMOTION} = \text{Dégoût}, \text{HATE} = \text{OAG}) = 0.26$   
 $p < 0.001, n_{\cap} = 74$
- $\rho(\text{EMOTION} = \text{Dégoût}, \text{HATE} = \text{NAG}) = -0.21$   
 $p < 0.001, n_{\cap} = 3$
- $\rho(\text{EMOTION} = \text{Colère}, \text{HATE} = \text{NAG}) = -0.17$   
 $p < 0.001, n_{\cap} = 66$
- $\rho(\text{EMOTION} = \text{Colère}, \text{HATE} = \text{CAG}) = -0.15$   
 $p < 0.001, n_{\cap} = 16$

### Global : $\chi^2$

- $\chi^2(\text{HATE}, \text{EMOTION} = \text{Colère}) = 55.13$   
 $p < 0.001$
- $\chi^2(\text{HATE}, \text{EMOTION} = \text{Dégoût}) = 51.78$   
 $p < 0.001$
- $\chi^2(\text{HATE}, \text{EMOTION} = \text{Autre}) = 7.54$   
 $p < 0.05$
- $\chi^2(\text{HATE}, \text{EMOTION} = \text{Culpabilité}) = 6.00$   
 $p = 0.05$
- $\chi^2(\text{HATE}, \text{EMOTION} = \text{Fierté}) = 6.00$   
 $p = 0.05$

## 2.2.7 Émotions × violence verbale

---

### Pairwise : $\rho$

- $\rho(\text{EMOTION} = \text{Dégoût}, \text{VAB} = \text{DNG}) = 0.30$   
 $p < 0.001, n_{\cap} = 35$
- $\rho(\text{EMOTION} = \text{Dégoût}, \text{VAB} = \text{OTH}) = -0.28$   
 $p < 0.001, n_{\cap} = 23$
- $\rho(\text{EMOTION} = \text{Dégoût}, \text{VAB} = \text{NCG}) = 0.16$   
 $p < 0.001, n_{\cap} = 19$
- $\rho(\text{EMOTION} = \text{Colère}, \text{VAB} = \text{DNG}) = -0.14$   
 $p < 0.005, n_{\cap} = 26$
- $\rho(\text{EMOTION} = \text{Dégoût}, \text{VAB} = \text{THR}) = -0.11$   
 $p < 0.05, n_{\cap} = 0$

### Global : $\chi^2$

- $\chi^2(\text{VAB}, \text{EMOTION} = \text{Dégoût}) = 71.21$   
 $p < 0.001$
- $\chi^2(\text{VAB}, \text{EMOTION} = \text{Colère}) = 12.35$   
 $p < 0.05$
- $\chi^2(\text{VAB}, \text{EMOTION} = \text{Autre}) = 6.62$   
 $p = 0.16$
- $\chi^2(\text{VAB}, \text{EMOTION} = \text{Peur}) = 3.96$   
 $p = 0.41$
- $\chi^2(\text{VAB}, \text{EMOTION} = \text{Joie}) = 3.66$   
 $p = 0.45$

## 2.2.8 Émotions × intention

---

### Pairwise : $\rho$

- $\rho(\text{EMOTION} = \text{Colère}, \text{INT} = \text{DFN}) = 0.25$   
 $p < 0.001, n_{\cap} = 127$
- $\rho(\text{EMOTION} = \text{Colère}, \text{INT} = \text{OTH}) = -0.18$   
 $p < 0.001, n_{\cap} = 18$
- $\rho(\text{EMOTION} = \text{Fierté}, \text{INT} = \text{CNS}) = 0.16$   
 $p < 0.001, n_{\cap} = 2$
- $\rho(\text{EMOTION} = \text{Dégoût}, \text{INT} = \text{AIN}) = 0.16$   
 $p < 0.001, n_{\cap} = 15$
- $\rho(\text{EMOTION} = \text{Culpabilité}, \text{INT} = \text{OTH}) = 0.15$   
 $p < 0.001, n_{\cap} = 3$

### Global : $\chi^2$

- $\chi^2(\text{INT}, \text{EMOTION} = \text{Colère}) = 72.93$   
 $p < 0.001$
- $\chi^2(\text{INT}, \text{EMOTION} = \text{Dégoût}) = 50.45$   
 $p < 0.001$
- $\chi^2(\text{INT}, \text{EMOTION} = \text{Fierté}) = 22.55$   
 $p < 0.005$
- $\chi^2(\text{INT}, \text{EMOTION} = \text{Culpabilité}) = 17.99$   
 $p < 0.05$
- $\chi^2(\text{INT}, \text{EMOTION} = \text{Tristesse}) = 14.26$   
 $p = 0.05$

## 2.2.9 Émotions × cible

---

### Pairwise : $\rho$

- $\rho(\text{EMOTION} = \text{Colère}, \text{TARGET} = \text{victim}) = -0.27$   
 $p < 0.001, n_{\cap} = 60$
- $\rho(\text{EMOTION} = \text{Dégoût}, \text{TARGET} = \text{victim}) = 0.25$   
 $p < 0.001, n_{\cap} = 55$
- $\rho(\text{EMOTION} = \text{Jalousie}, \text{TARGET} = \text{bully\_support}) = 0.18$   
 $p < 0.001, n_{\cap} = 4$
- $\rho(\text{EMOTION} = \text{Colère}, \text{TARGET} = \text{bully}) = 0.17$   
 $p < 0.001, n_{\cap} = 70$
- $\rho(\text{EMOTION} = \text{Colère}, \text{TARGET} = \text{bully\_support}) = 0.16$   
 $p < 0.001, n_{\cap} = 60$

### Global : $\chi^2$

- $\chi^2(\text{TARGET}, \text{EMOTION} = \text{Colère}) = 52.89$   
 $p < 0.001$
- $\chi^2(\text{TARGET}, \text{EMOTION} = \text{Dégoût}) = 36.91$   
 $p < 0.001$
- $\chi^2(\text{TARGET}, \text{EMOTION} = \text{Jalousie}) = 21.17$   
 $p < 0.05$
- $\chi^2(\text{TARGET}, \text{EMOTION} = \text{Embarras}) = 13.24$   
 $p = 0.15$
- $\chi^2(\text{TARGET}, \text{EMOTION} = \text{Autre}) = 10.00$   
 $p = 0.35$

## 2.2.10 Émotions × rôle

---

### Pairwise : $\rho$

- $\rho(\text{EMOTION} = \text{Dégoût}, \text{ROLE} = \text{bully}) = 0.14$   
 $p < 0.001, n_{\cap} = 23$
- $\rho(\text{EMOTION} = \text{Colère}, \text{ROLE} = \text{bully\_support}) = -0.14$   
 $p < 0.001, n_{\cap} = 74$
- $\rho(\text{EMOTION} = \text{Tristesse}, \text{ROLE} = \text{victim}) = 0.13$   
 $p < 0.001, n_{\cap} = 6$
- $\rho(\text{EMOTION} = \text{Colère}, \text{ROLE} = \text{victim}) = 0.13$   
 $p < 0.001, n_{\cap} = 48$
- $\rho(\text{EMOTION} = \text{Dégoût}, \text{ROLE} = \text{conciliator}) = -0.13$   
 $p < 0.001, n_{\cap} = 4$

### Global : $\chi^2$

- $\chi^2(\text{ROLE}, \text{EMOTION} = \text{Dégoût}) = 34.60$   
 $p < 0.001$
- $\chi^2(\text{ROLE}, \text{EMOTION} = \text{Colère}) = 25.67$   
 $p < 0.001$
- $\chi^2(\text{ROLE}, \text{EMOTION} = \text{Tristesse}) = 17.71$   
 $p < 0.005$
- $\chi^2(\text{ROLE}, \text{EMOTION} = \text{Autre}) = 15.47$   
 $p < 0.005$
- $\chi^2(\text{ROLE}, \text{EMOTION} = \text{Joie}) = 9.70$   
 $p = 0.05$

## 2.2.11 Émotions × contexte

---

### Pairwise : $\rho$

- $\rho(\text{EMOTION} = \text{Embarras}, \text{CTX} = \text{CR}) = 0.23$   
 $p < 0.005, n_{\cap} = 1$
- $\rho(\text{EMOTION} = \text{Colère}, \text{CTX} = \text{ATK}) = 0.16$   
 $p < 0.001, n_{\cap} = 128$
- $\rho(\text{EMOTION} = \text{Culpabilité}, \text{CTX} = \text{CR}) = 0.16$   
 $p = 0.05, n_{\cap} = 1$
- $\rho(\text{EMOTION} = \text{Surprise}, \text{CTX} = \text{EMP}) = 0.13$   
 $p = 0.12, n_{\cap} = 1$
- $\rho(\text{EMOTION} = \text{Colère}, \text{CTX} = \text{OTH}) = -0.12$   
 $p < 0.005, n_{\cap} = 18$

### Global : $\chi^2$

- $\chi^2(\text{CTX}, \text{EMOTION} = \text{Embarras}) = 35.50$   
 $p < 0.001$
- $\chi^2(\text{CTX}, \text{EMOTION} = \text{Colère}) = 23.36$   
 $p < 0.005$
- $\chi^2(\text{CTX}, \text{EMOTION} = \text{Culpabilité}) = 20.44$   
 $p < 0.005$
- $\chi^2(\text{CTX}, \text{EMOTION} = \text{Surprise}) = 18.15$   
 $p < 0.05$
- $\chi^2(\text{CTX}, \text{EMOTION} = \text{Dégoût}) = 12.67$   
 $p = 0.08$

## 2.2.12 Modes d'expression × haine / agressivité

---

### Pairwise : $\rho$

- $\rho(\text{MODE} = \text{Montrée}, \text{HATE} = \text{OAG}) = 0.33$   
 $p < 0.001, n_{\cap} = 226$
- $\rho(\text{MODE} = \text{Montrée}, \text{HATE} = \text{NAG}) = -0.26$   
 $p < 0.001, n_{\cap} = 54$
- $\rho(\text{MODE} = \text{Montrée}, \text{HATE} = \text{CAG}) = -0.13$   
 $p < 0.001, n_{\cap} = 20$
- $\rho(\text{MODE} = \text{Désignée}, \text{HATE} = \text{CAG}) = -0.07$   
 $p = 0.08, n_{\cap} = 2$
- $\rho(\text{MODE} = \text{Désignée}, \text{HATE} = \text{OAG}) = 0.07$   
 $p = 0.07, n_{\cap} = 37$

### Global : $\chi^2$

- $\chi^2(\text{HATE}, \text{MODE} = \text{Montrée}) = 83.92$   
 $p < 0.001$
- $\chi^2(\text{HATE}, \text{MODE} = \text{Désignée}) = 5.45$   
 $p = 0.07$
- $\chi^2(\text{HATE}, \text{MODE} = \text{Comportementale}) = 3.07$   
 $p = 0.22$
- $\chi^2(\text{HATE}, \text{MODE} = \text{Suggérée}) = 2.24$   
 $p = 0.33$

## 2.2.13 Modes d'expression $\times$ violence verbale

---

### Pairwise : $\rho$

- $\rho(\text{MODE} = \text{Comportementale}, \text{VAB} = \text{THR}) = 0.17$   
 $p < 0.001, n_{\cap} = 6$
- $\rho(\text{MODE} = \text{Montrée}, \text{VAB} = \text{NCG}) = 0.13$   
 $p < 0.005, n_{\cap} = 41$
- $\rho(\text{MODE} = \text{Désignée}, \text{VAB} = \text{DNG}) = 0.09$   
 $p = 0.05, n_{\cap} = 12$
- $\rho(\text{MODE} = \text{Désignée}, \text{VAB} = \text{NCG}) = -0.08$   
 $p = 0.10, n_{\cap} = 1$
- $\rho(\text{MODE} = \text{Comportementale}, \text{VAB} = \text{NCG}) = -0.08$   
 $p = 0.15, n_{\cap} = 0$

### Global : $\chi^2$

- $\chi^2(\text{VAB}, \text{MODE} = \text{Comportementale}) = 17.60$   
 $p < 0.005$
- $\chi^2(\text{VAB}, \text{MODE} = \text{Montrée}) = 12.44$   
 $p < 0.05$
- $\chi^2(\text{VAB}, \text{MODE} = \text{Désignée}) = 10.04$   
 $p < 0.05$
- $\chi^2(\text{VAB}, \text{MODE} = \text{Suggérée}) = 4.37$   
 $p = 0.36$

## 2.2.14 Modes d'expression $\times$ intention

---

### Pairwise : $\rho$

- $\rho(\text{MODE} = \text{Montrée}, \text{INT} = \text{OTH}) = -0.21$   
 $p < 0.001, n_{\cap} = 15$
- $\rho(\text{MODE} = \text{Montrée}, \text{INT} = \text{DFN}) = 0.21$   
 $p < 0.001, n_{\cap} = 123$
- $\rho(\text{MODE} = \text{Montrée}, \text{INT} = \text{EMP}) = -0.11$   
 $p < 0.01, n_{\cap} = 2$
- $\rho(\text{MODE} = \text{Suggérée}, \text{INT} = \text{EMP}) = 0.07$   
 $p = 0.11, n_{\cap} = 4$
- $\rho(\text{MODE} = \text{Désignée}, \text{INT} = \text{DFN}) = -0.07$   
 $p = 0.09, n_{\cap} = 10$

### Global : $\chi^2$

- $\chi^2(\text{INT}, \text{MODE} = \text{Montrée}) = 68.60$   
 $p < 0.001$
- $\chi^2(\text{INT}, \text{MODE} = \text{Suggérée}) = 7.98$   
 $p = 0.33$
- $\chi^2(\text{INT}, \text{MODE} = \text{Désignée}) = 6.77$   
 $p = 0.45$
- $\chi^2(\text{INT}, \text{MODE} = \text{Comportementale}) = 5.54$   
 $p = 0.59$

## 2.2.15 Modes d'expression × cible

---

### Pairwise : $\rho$

- $\rho(\text{MODE} = \text{Montrée}, \text{TARGET} = \text{victim}) = -0.17$   
 $p < 0.001, n_{\cap} = 82$
- $\rho(\text{MODE} = \text{Désignée}, \text{TARGET} = \text{victim}) = 0.13$   
 $p < 0.01, n_{\cap} = 25$
- $\rho(\text{MODE} = \text{Montrée}, \text{TARGET} = \text{bully}) = 0.11$   
 $p < 0.05, n_{\cap} = 70$
- $\rho(\text{MODE} = \text{Montrée}, \text{TARGET} = \text{bully\_support}) = 0.11$   
 $p < 0.05, n_{\cap} = 60$
- $\rho(\text{MODE} = \text{Désignée}, \text{TARGET} = \text{bully}) = -0.09$   
 $p = 0.07, n_{\cap} = 4$

### Global : $\chi^2$

- $\chi^2(\text{TARGET}, \text{MODE} = \text{Montrée}) = 25.56$   
 $p < 0.005$
- $\chi^2(\text{TARGET}, \text{MODE} = \text{Désignée}) = 13.25$   
 $p = 0.15$
- $\chi^2(\text{TARGET}, \text{MODE} = \text{Suggérée}) = 6.66$   
 $p = 0.67$
- $\chi^2(\text{TARGET}, \text{MODE} = \text{Comportementale}) = 4.55$   
 $p = 0.87$

## 2.2.16 Modes d'expression $\times$ rôle

---

### Pairwise : $\rho$

- $\rho(\text{MODE} = \text{Montrée}, \text{ROLE} = \text{victim}) = 0.09$   
 $p < 0.05, n_{\cap} = 45$
- $\rho(\text{MODE} = \text{Montrée}, \text{ROLE} = \text{conciliator}) = -0.08$   
 $p < 0.05, n_{\cap} = 48$
- $\rho(\text{MODE} = \text{Montrée}, \text{ROLE} = \text{bully\_support}) = -0.07$   
 $p = 0.06, n_{\cap} = 90$
- $\rho(\text{MODE} = \text{Désignée}, \text{ROLE} = \text{bully\_support}) = 0.07$   
 $p = 0.09, n_{\cap} = 25$
- $\rho(\text{MODE} = \text{Montrée}, \text{ROLE} = \text{bully}) = 0.06$   
 $p = 0.15, n_{\cap} = 50$

### Global : $\chi^2$

- $\chi^2(\text{ROLE}, \text{MODE} = \text{Montrée}) = 15.37$   
 $p < 0.005$
- $\chi^2(\text{ROLE}, \text{MODE} = \text{Désignée}) = 4.60$   
 $p = 0.33$
- $\chi^2(\text{ROLE}, \text{MODE} = \text{Comportementale}) = 3.21$   
 $p = 0.52$
- $\chi^2(\text{ROLE}, \text{MODE} = \text{Suggérée}) = 0.66$   
 $p = 0.96$

## 2.2.17 Modes d'expression $\times$ contexte

---

### Pairwise : $\rho$

- $\rho(\text{MODE} = \text{Montrée}, \text{CTX} = \text{OTH}) = -0.13$   
 $p < 0.005, n_{\cap} = 18$
- $\rho(\text{MODE} = \text{Montrée}, \text{CTX} = \text{ATK}) = 0.12$   
 $p < 0.005, n_{\cap} = 127$
- $\rho(\text{MODE} = \text{Suggérée}, \text{CTX} = \text{CR}) = 0.07$   
 $p = 0.17, n_{\cap} = 3$
- $\rho(\text{MODE} = \text{Comportementale}, \text{CTX} = \text{ATK}) = 0.07$   
 $p = 0.11, n_{\cap} = 17$
- $\rho(\text{MODE} = \text{Désignée}, \text{CTX} = \text{CR}) = 0.07$   
 $p = 0.20, n_{\cap} = 3$

### Global : $\chi^2$

- $\chi^2(\text{CTX}, \text{MODE} = \text{Montrée}) = 19.34$   
 $p < 0.01$
- $\chi^2(\text{CTX}, \text{MODE} = \text{Comportementale}) = 9.08$   
 $p = 0.25$
- $\chi^2(\text{CTX}, \text{MODE} = \text{Désignée}) = 7.53$   
 $p = 0.38$
- $\chi^2(\text{CTX}, \text{MODE} = \text{Suggérée}) = 6.77$   
 $p = 0.45$


## 2.2.18 Points d'attention

---


- Le maximum identifié est désormais  $|\rho| = 0.75$ , porté par Colère–Montrée.
- Les formules avec  $n_{\cap}$  très faible doivent être lues comme des signaux exploratoires.
- Les scores  $\chi^2$  indiquent une dépendance globale, sans isoler à eux seuls quel niveau catégoriel porte toute l'association.
- Une lecture inférentielle stricte demanderait une correction des comparaisons multiples.

### **3. Tests du modèle EMOTYC**

## 3.1 Qu'est-ce qu'EMOTYC ?



## 3.2 Méthodologie utilisée pour les tests de performance



## 3.2.1 Métriques utilisées

---

La précision mesure la fiabilité des prédictions positives :

$$\text{Precision} = \frac{TP}{TP + FP}$$

Le rappel mesure la capacité du modèle à retrouver les instances réellement positives :

$$\text{Recall} = \frac{TP}{TP + FN}$$

## 3.2.2 Interpréter les baisses de performance

---

- Une baisse de précision suggère que certains indices lexicaux ou contextuels valides dans TTK deviennent trompeurs dans CyberAggAdoLarge.
- Une baisse de rappel suggère que l'émotion concernée est exprimée dans CyberAggAdoLarge par des formes lexicales, discursives ou contextuelles différentes de celles apprises sur TTK. EMOTYC n'ayant jamais vu ces formes, il ne les détecte pas ou les associe à tort à un autre label émotionnel.

### 3.3.1 Ce que mesure la heatmap

---

$$\Delta_m(\ell) = m_{\text{TextToKids}}(\ell) - m_{\text{CyberAggAdo}}(\ell)$$

- Les colonnes comparent  $F_1$ , la précision et le rappel, label par label.
- La couleur encode  $|\Delta|$  : vert clair si les performances sont proches, orange/rouge si l'écart est fort.
- Une valeur positive signifie que le modèle performe mieux sur TextToKids que sur CyberAggAdo.

| Corpus      | Unités textuelles |
|-------------|-------------------|
| TextToKids  | 27 911            |
| CyberAggAdo | 781               |

Configuration : template avec contexte, seuil 0.5, comparaison directe des résumés JSON.

### 3.3.2 Heatmap compacte des principaux labels

---

| Label   | Cyber | $\Delta F_1$ | $\Delta P$ | $\Delta R$ |
|---------|-------|--------------|------------|------------|
| Émo     | 398   | +0.27        | +0.31      | +0.23      |
| Base    | 363   | +0.37        | +0.29      | +0.43      |
| Montrée | 300   | +0.41        | +0.42      | +0.41      |
| Colère  | 289   | +0.46        | +0.42      | +0.49      |
| Autre   | 62    | +0.76        | +0.78      | +0.68      |

Lecture : 4 labels les plus représentés dans CyberAggAdoLarge, plus le plus fort décrochage robuste.  $\Delta > 0$  indique une performance supérieure sur TextToKids ; la couleur indique l'amplitude, pas le sens.

### 3.3.3 Signal principal : forte perte hors domaine

---

+0.4570

Macro  $F_1$

écart TextToKids – CyberAggAdo

+0.4236

Micro  $F_1$

écart TextToKids – CyberAggAdo

781

unités CyberAggAdo

contre 27 911 pour TextToKids

- Le modèle conserve une détection globale de l'émotion, mais les performances baissent nettement en transfert.
- Les labels fréquents dans CyberAggAdoLarge montrent déjà un décrochage substantiel : *Émo* ( $\Delta F_1 = +0.27$ ), *Base* (+0.37), *Montrée* (+0.41), *Colère* (+0.46).
- Le décalage touche à la fois la précision et le rappel, ce qui suggère des faux positifs et des faux négatifs hors domaine.

### 3.3.4 Labels concentrant le décrochage

---

| Label    | Cyber | TTK   | $\Delta F_1$ | $\Delta P$ | $\Delta R$ |
|----------|-------|-------|--------------|------------|------------|
| Autre    | 62    | 1 270 | +0.76        | +0.78      | +0.68      |
| Suggérée | 54    | 1 909 | +0.73        | +0.67      | +0.74      |
| Désignée | 55    | 1 499 | +0.56        | +0.50      | +0.60      |
| Colère   | 289   | 1 180 | +0.46        | +0.42      | +0.49      |
| Montrée  | 300   | 971   | +0.41        | +0.42      | +0.41      |
| Base     | 363   | 4 133 | +0.37        | +0.29      | +0.43      |

- Le mode *Suggérée* décroche fortement : les indices contextuels appris sur TextToKids transfèrent mal vers les messages de cyberharcèlement.
- *Autre* est le plus grand écart parmi les labels avec au moins 50 occurrences positives dans CyberAggAdoLarge.
- *Colère* et *Montrée* restent suffisamment représentés pour signaler une vraie difficulté, pas seulement un bruit d'effectif.

### 3.3.5 Points de vigilance

---


- Les labels très rares dans CyberAggAdoLarge doivent être interprétés avec prudence : *Admiration* a 0 occurrence positive, *Embarras* 2, *Fierté* 3, *Peur* 4.
- La couleur ne distingue pas le signe : une case claire peut aussi correspondre à une absence de cas suffisants pour comparer.
- La heatmap sert surtout à localiser les zones de non-transférabilité ; l'analyse qualitative des erreurs reste nécessaire pour expliquer les mécanismes.

Conclusion : EMOTYC apprend bien le domaine TextToKids, mais les formes discursives de CyberAggAdoLarge changent assez pour dégrader la généralisation, notamment sur les modes d'expression et certains labels émotionnels.

## 4. Tests avec des classifieurs linéaires

## 4.1 Classifieurs linéaires utilisés

---



## 4.2 Comparaison des performances des classifieurs linéaires aux performances d'EMOTYC

---

