

Leveraging linguistic annotations to improve automatic detection of online content

Gwendal Tsang

Valentina Dragos
Delphine Battistelli



- ❶ Problématique globale
- ❷ Le corpus CyberAggAdoLarge
- ❸ Tests du modèle EMOTYC
- ❹ Tests avec des classifieurs linéaires

1. Problématique globale

Les annotations linguistiques et émotionnelles peuvent-elles améliorer ou éclairer l'analyse et la détection des conversations de cyberharcèlement ?

2. Le corpus CyberAggAdoLarge

2.1.1 Annotations du corpus CyberAggAdo utilisées

EMOTION émotion repérée dans l'énoncé : colère, dégoût, joie, tristesse, etc.

MODE mode d'expression de l'émotion : suggérée, montrée, comportementale ou désignée.

ROLE de l'autre : victim, bully, bully_support, victim_support ou conciliator.

TARGET rôle de la cible du message.

HATE degré d'agressivité du message : ouverte, couverte ou absente.

VAB type de violence verbale : blâme, dénigrement, insulte, menace ou autre.

INT intention du message : attaquer, défendre, apaiser, encourager, etc.

CTX contexte interactionnel dans lequel l'énoncé répond ou s'inscrit.

2.1.2 Explication de la signification des étiquettes 1

ROLE / TARGET

bully personne qui initie le harcèlement.

victim personne harcelée.

bully_support personnes qui aident le harceleur.

victim_support personnes qui aident la victime.

conciliator personnes qui cherchent à médiatiser le désaccord.

HATE

OAG agressivité ouverte : hostilité explicite, menace, insulte ou haine directe.

CAG agressivité couverte : agressivité masquée, indirecte ou implicite.

NAG non agressif : absence de menace, insulte ou intimidation.

2.1.3 Explication de la signification des étiquettes 2

VAB

- BLM** blâme : rendre la victime responsable de l'abus.
- DNG** dénigrement : remarques blessantes et non constructives.
- NCG** insultes ou name calling.
- THR** menace visant à effrayer ou contraindre.
- OTH** autre.

INT / CTX

- ATK** attaque : agression délibérée, moquerie, exclusion ou discrédit.
- DFN** défense : réponse protectrice à une attaque.
- CNS** contre-discours non agressif contre un discours nuisible.
- AIN** incitation ou validation d'un message négatif.
- GSL** gaslighting : minimisation ou invalidation du vécu de la victime.
- EMP** empathie, compassion ou soutien.
- CR** résolution de conflit, médiation ou désescalade.
- OTH** intention peu claire, énoncé neutre ou fragmentaire.

2.2.1 Lecture de la notation

- $\rho(X = a, Y = b)$ reprend le coefficient Phi pour une paire de variables binaires.
- $\chi^2(F, X = a)$ résume le test global entre une famille catégorielle F et une variable binaire.
- Les p-values très petites sont ramenées à des seuils : $p < 0.05$, $p < 0.01$, $p < 0.005$ ou $p < 0.001$.
- $n_{\cap}$ indique le nombre de cooccurrences de la paire.

2.2.2 Plus fortes corrélations pairwise

Top 1-5

- $\rho(\text{EMOTION} = \text{Colère}, \text{MODE} = \text{Montrée}) = 0.75$
 $p < 0.001, n_{\cap} = 249$
- $\rho(\text{EMOTION} = \text{Joie}, \text{MODE} = \text{Désignée}) = 0.36$
 $p < 0.001, n_{\cap} = 16$
- $\rho(\text{MODE} = \text{Montrée}, \text{HATE} = \text{OAG}) = 0.33$
 $p < 0.001, n_{\cap} = 226$
- $\rho(\text{EMOTION} = \text{Dégoût}, \text{MODE} = \text{Montrée}) = 0.33$
 $p < 0.001, n_{\cap} = 69$
- $\rho(\text{EMOTION} = \text{Jalousie}, \text{MODE} = \text{Désignée}) = 0.32$
 $p < 0.001, n_{\cap} = 6$

Top 6-10

- $\rho(\text{EMOTION} = \text{Dégoût}, \text{VAB} = \text{DNG}) = 0.30$
 $p < 0.001, n_{\cap} = 35$
- $\rho(\text{EMOTION} = \text{Dégoût}, \text{VAB} = \text{OTH}) = -0.28$
 $p < 0.001, n_{\cap} = 23$
- $\rho(\text{EMOTION} = \text{Tristesse}, \text{MODE} = \text{Suggérée}) = 0.27$
 $p < 0.001, n_{\cap} = 8$
- $\rho(\text{EMOTION} = \text{Colère}, \text{TARGET} = \text{victim}) = -0.27$
 $p < 0.001, n_{\cap} = 60$
- $\rho(\text{EMOTION} = \text{Colère}, \text{HATE} = \text{OAG}) = 0.26$
 $p < 0.001, n_{\cap} = 207$

2.2.3 Plus fortes associations globales

Top 1-5

- $\chi^2(\text{HATE}, \text{MODE} = \text{Montrée}) = 83.92$
 $p < 0.001$
- $\chi^2(\text{INT}, \text{EMOTION} = \text{Colère}) = 72.93$
 $p < 0.001$
- $\chi^2(\text{VAB}, \text{EMOTION} = \text{Dégoût}) = 71.21$
 $p < 0.001$
- $\chi^2(\text{INT}, \text{MODE} = \text{Montrée}) = 68.60$
 $p < 0.001$
- $\chi^2(\text{HATE}, \text{EMOTION} = \text{Colère}) = 55.13$
 $p < 0.001$

Top 6-10

- $\chi^2(\text{TARGET}, \text{EMOTION} = \text{Colère}) = 52.89$
 $p < 0.001$
- $\chi^2(\text{HATE}, \text{EMOTION} = \text{Dégoût}) = 51.78$
 $p < 0.001$
- $\chi^2(\text{INT}, \text{EMOTION} = \text{Dégoût}) = 50.45$
 $p < 0.001$
- $\chi^2(\text{TARGET}, \text{EMOTION} = \text{Dégoût}) = 36.91$
 $p < 0.001$
- $\chi^2(\text{CTX}, \text{EMOTION} = \text{Embarras}) = 35.50$
 $p < 0.001$

2.2.4 Lecture rapide des résultats

- Le signal pairwise maximal devient $\rho(\text{EMOTION} = \text{Colère}, \text{MODE} = \text{Montrée}) = 0.75$.
- Les autres liens émotion-mode les plus visibles sont Joie–Désignée, Dégoût–Montrée, Jalousie–Désignée et Tristesse–Suggérée.
- **Dégoût** concentre aussi des liens marqués avec la violence verbale : DNG positif et OTH négatif.
- **Colère** reste associée à HATE :OAG et INT :DFN, mais inversement à HATE :NAG et TARGET :victim.

2.2.5 Émotions × modes d'expression

Top pairwise : ρ

- $\rho(\text{EMOTION} = \text{Colère}, \text{MODE} = \text{Montrée}) = 0.75$
 $p < 0.001, n_{\cap} = 249$
- $\rho(\text{EMOTION} = \text{Joie}, \text{MODE} = \text{Désignée}) = 0.36$
 $p < 0.001, n_{\cap} = 16$
- $\rho(\text{EMOTION} = \text{Dégoût}, \text{MODE} = \text{Montrée}) = 0.33$
 $p < 0.001, n_{\cap} = 69$
- $\rho(\text{EMOTION} = \text{Jalousie}, \text{MODE} = \text{Désignée}) = 0.32$
 $p < 0.001, n_{\cap} = 6$
- $\rho(\text{EMOTION} = \text{Tristesse}, \text{MODE} = \text{Suggérée}) = 0.27$
 $p < 0.001, n_{\cap} = 8$

Lecture

- La corrélation Colère–Montrée domine nettement tous les autres résultats.
- Dégoût suit le même axe expressif que Colère, mais avec un effet plus modéré.
- Joie et Jalousie ressortent avec le mode Désignée ; Jalousie reste portée par un petit effectif.
- Tristesse apparaît surtout du côté Suggérée dans ce top.

2.2.6 Émotions $\times$ haine / agressivité

Pairwise : ρ

- $\rho(\text{EMOTION} = \text{Colère}, \text{HATE} = \text{OAG}) = 0.26$
 $p < 0.001, n_{\cap} = 207$
- $\rho(\text{EMOTION} = \text{Dégoût}, \text{HATE} = \text{OAG}) = 0.26$
 $p < 0.001, n_{\cap} = 74$
- $\rho(\text{EMOTION} = \text{Dégoût}, \text{HATE} = \text{NAG}) = -0.21$
 $p < 0.001, n_{\cap} = 3$
- $\rho(\text{EMOTION} = \text{Colère}, \text{HATE} = \text{NAG}) = -0.17$
 $p < 0.001, n_{\cap} = 66$
- $\rho(\text{EMOTION} = \text{Colère}, \text{HATE} = \text{CAG}) = -0.15$
 $p < 0.001, n_{\cap} = 16$

Global : χ^2

- $\chi^2(\text{HATE}, \text{EMOTION} = \text{Colère}) = 55.13$
 $p < 0.001$
- $\chi^2(\text{HATE}, \text{EMOTION} = \text{Dégoût}) = 51.78$
 $p < 0.001$
- $\chi^2(\text{HATE}, \text{EMOTION} = \text{Autre}) = 7.54$
 $p < 0.05$
- $\chi^2(\text{HATE}, \text{EMOTION} = \text{Culpabilité}) = 6.00$
 $p = 0.05$
- $\chi^2(\text{HATE}, \text{EMOTION} = \text{Fierté}) = 6.00$
 $p = 0.05$

2.2.7 Émotions × intention

Pairwise : ρ

- $\rho(\text{EMOTION} = \text{Colère}, \text{INT} = \text{DFN}) = 0.25$
 $p < 0.001, n_{\cap} = 127$
- $\rho(\text{EMOTION} = \text{Colère}, \text{INT} = \text{OTH}) = -0.18$
 $p < 0.001, n_{\cap} = 18$
- $\rho(\text{EMOTION} = \text{Fierté}, \text{INT} = \text{CNS}) = 0.16$
 $p < 0.001, n_{\cap} = 2$
- $\rho(\text{EMOTION} = \text{Dégoût}, \text{INT} = \text{AIN}) = 0.16$
 $p < 0.001, n_{\cap} = 15$
- $\rho(\text{EMOTION} = \text{Culpabilité}, \text{INT} = \text{OTH}) = 0.15$
 $p < 0.001, n_{\cap} = 3$

Global : χ^2

- $\chi^2(\text{INT}, \text{EMOTION} = \text{Colère}) = 72.93$
 $p < 0.001$
- $\chi^2(\text{INT}, \text{EMOTION} = \text{Dégoût}) = 50.45$
 $p < 0.001$
- $\chi^2(\text{INT}, \text{EMOTION} = \text{Fierté}) = 22.55$
 $p < 0.005$
- $\chi^2(\text{INT}, \text{EMOTION} = \text{Culpabilité}) = 17.99$
 $p < 0.05$
- $\chi^2(\text{INT}, \text{EMOTION} = \text{Tristesse}) = 14.26$
 $p = 0.05$

2.2.8 Émotions × cible

Pairwise : ρ

- $\rho(\text{EMOTION} = \text{Colère}, \text{TARGET} = \text{victim}) = -0.27$
 $p < 0.001, n_{\cap} = 60$
- $\rho(\text{EMOTION} = \text{Dégoût}, \text{TARGET} = \text{victim}) = 0.25$
 $p < 0.001, n_{\cap} = 55$
- $\rho(\text{EMOTION} = \text{Jalousie}, \text{TARGET} = \text{bully_support}) = 0.18$
 $p < 0.001, n_{\cap} = 4$
- $\rho(\text{EMOTION} = \text{Colère}, \text{TARGET} = \text{bully}) = 0.17$
 $p < 0.001, n_{\cap} = 70$
- $\rho(\text{EMOTION} = \text{Colère}, \text{TARGET} = \text{bully_support}) = 0.16$
 $p < 0.001, n_{\cap} = 60$

Global : χ^2

- $\chi^2(\text{TARGET}, \text{EMOTION} = \text{Colère}) = 52.89$
 $p < 0.001$
- $\chi^2(\text{TARGET}, \text{EMOTION} = \text{Dégoût}) = 36.91$
 $p < 0.001$
- $\chi^2(\text{TARGET}, \text{EMOTION} = \text{Jalousie}) = 21.17$
 $p < 0.05$
- $\chi^2(\text{TARGET}, \text{EMOTION} = \text{Embarras}) = 13.24$
 $p = 0.15$
- $\chi^2(\text{TARGET}, \text{EMOTION} = \text{Autre}) = 10.00$
 $p = 0.35$

2.2.9 Émotions × rôle

Pairwise : ρ

- $\rho(\text{EMOTION} = \text{Dégoût}, \text{ROLE} = \text{bully}) = 0.14$
 $p < 0.001, n_{\cap} = 23$
- $\rho(\text{EMOTION} = \text{Colère}, \text{ROLE} = \text{bully_support}) = -0.14$
 $p < 0.001, n_{\cap} = 74$
- $\rho(\text{EMOTION} = \text{Tristesse}, \text{ROLE} = \text{victim}) = 0.13$
 $p < 0.001, n_{\cap} = 6$
- $\rho(\text{EMOTION} = \text{Colère}, \text{ROLE} = \text{victim}) = 0.13$
 $p < 0.001, n_{\cap} = 48$
- $\rho(\text{EMOTION} = \text{Dégoût}, \text{ROLE} = \text{conciliator}) = -0.13$
 $p < 0.001, n_{\cap} = 4$

Global : χ^2

- $\chi^2(\text{ROLE}, \text{EMOTION} = \text{Dégoût}) = 34.60$
 $p < 0.001$
- $\chi^2(\text{ROLE}, \text{EMOTION} = \text{Colère}) = 25.67$
 $p < 0.001$
- $\chi^2(\text{ROLE}, \text{EMOTION} = \text{Tristesse}) = 17.71$
 $p < 0.005$
- $\chi^2(\text{ROLE}, \text{EMOTION} = \text{Autre}) = 15.47$
 $p < 0.005$
- $\chi^2(\text{ROLE}, \text{EMOTION} = \text{Joie}) = 9.70$
 $p = 0.05$

2.2.10 Émotions × contexte

Pairwise : ρ

- $\rho(\text{EMOTION} = \text{Embarras}, \text{CTX} = \text{CR}) = 0.23$
 $p < 0.005, n_{\cap} = 1$
- $\rho(\text{EMOTION} = \text{Colère}, \text{CTX} = \text{ATK}) = 0.16$
 $p < 0.001, n_{\cap} = 128$
- $\rho(\text{EMOTION} = \text{Culpabilité}, \text{CTX} = \text{CR}) = 0.16$
 $p = 0.05, n_{\cap} = 1$
- $\rho(\text{EMOTION} = \text{Surprise}, \text{CTX} = \text{EMP}) = 0.13$
 $p = 0.12, n_{\cap} = 1$
- $\rho(\text{EMOTION} = \text{Colère}, \text{CTX} = \text{OTH}) = -0.12$
 $p < 0.005, n_{\cap} = 18$

Global : χ^2

- $\chi^2(\text{CTX}, \text{EMOTION} = \text{Embarras}) = 35.50$
 $p < 0.001$
- $\chi^2(\text{CTX}, \text{EMOTION} = \text{Colère}) = 23.36$
 $p < 0.005$
- $\chi^2(\text{CTX}, \text{EMOTION} = \text{Culpabilité}) = 20.44$
 $p < 0.005$
- $\chi^2(\text{CTX}, \text{EMOTION} = \text{Surprise}) = 18.15$
 $p < 0.05$
- $\chi^2(\text{CTX}, \text{EMOTION} = \text{Dégoût}) = 12.67$
 $p = 0.08$

2.2.11 Modes d'expression × haine / agressivité

Pairwise : ρ

- $\rho(\text{MODE} = \text{Montrée}, \text{HATE} = \text{OAG}) = 0.33$
 $p < 0.001, n_{\cap} = 226$
- $\rho(\text{MODE} = \text{Montrée}, \text{HATE} = \text{NAG}) = -0.26$
 $p < 0.001, n_{\cap} = 54$
- $\rho(\text{MODE} = \text{Montrée}, \text{HATE} = \text{CAG}) = -0.13$
 $p < 0.001, n_{\cap} = 20$
- $\rho(\text{MODE} = \text{Désignée}, \text{HATE} = \text{CAG}) = -0.07$
 $p = 0.08, n_{\cap} = 2$
- $\rho(\text{MODE} = \text{Désignée}, \text{HATE} = \text{OAG}) = 0.07$
 $p = 0.07, n_{\cap} = 37$

Global : χ^2

- $\chi^2(\text{HATE}, \text{MODE} = \text{Montrée}) = 83.92$
 $p < 0.001$
- $\chi^2(\text{HATE}, \text{MODE} = \text{Désignée}) = 5.45$
 $p = 0.07$
- $\chi^2(\text{HATE}, \text{MODE} = \text{Comportementale}) = 3.07$
 $p = 0.22$
- $\chi^2(\text{HATE}, \text{MODE} = \text{Suggérée}) = 2.24$
 $p = 0.33$

2.2.12 Modes d'expression $\times$ violence verbale

Pairwise : ρ

- $\rho(\text{MODE} = \text{Comportementale}, \text{VAB} = \text{THR}) = 0.17$
 $p < 0.001, n_{\cap} = 6$
- $\rho(\text{MODE} = \text{Montrée}, \text{VAB} = \text{NCG}) = 0.13$
 $p < 0.005, n_{\cap} = 41$
- $\rho(\text{MODE} = \text{Désignée}, \text{VAB} = \text{DNG}) = 0.09$
 $p = 0.05, n_{\cap} = 12$
- $\rho(\text{MODE} = \text{Désignée}, \text{VAB} = \text{NCG}) = -0.08$
 $p = 0.10, n_{\cap} = 1$
- $\rho(\text{MODE} = \text{Comportementale}, \text{VAB} = \text{NCG}) = -0.08$
 $p = 0.15, n_{\cap} = 0$

Global : χ^2

- $\chi^2(\text{VAB}, \text{MODE} = \text{Comportementale}) = 17.60$
 $p < 0.005$
- $\chi^2(\text{VAB}, \text{MODE} = \text{Montrée}) = 12.44$
 $p < 0.05$
- $\chi^2(\text{VAB}, \text{MODE} = \text{Désignée}) = 10.04$
 $p < 0.05$
- $\chi^2(\text{VAB}, \text{MODE} = \text{Suggérée}) = 4.37$
 $p = 0.36$

2.2.13 Modes d'expression $\times$ intention

Pairwise : ρ

- $\rho(\text{MODE} = \text{Montrée}, \text{INT} = \text{OTH}) = -0.21$
 $p < 0.001, n_{\cap} = 15$
- $\rho(\text{MODE} = \text{Montrée}, \text{INT} = \text{DFN}) = 0.21$
 $p < 0.001, n_{\cap} = 123$
- $\rho(\text{MODE} = \text{Montrée}, \text{INT} = \text{EMP}) = -0.11$
 $p < 0.01, n_{\cap} = 2$
- $\rho(\text{MODE} = \text{Suggérée}, \text{INT} = \text{EMP}) = 0.07$
 $p = 0.11, n_{\cap} = 4$
- $\rho(\text{MODE} = \text{Désignée}, \text{INT} = \text{DFN}) = -0.07$
 $p = 0.09, n_{\cap} = 10$

Global : χ^2

- $\chi^2(\text{INT}, \text{MODE} = \text{Montrée}) = 68.60$
 $p < 0.001$
- $\chi^2(\text{INT}, \text{MODE} = \text{Suggérée}) = 7.98$
 $p = 0.33$
- $\chi^2(\text{INT}, \text{MODE} = \text{Désignée}) = 6.77$
 $p = 0.45$
- $\chi^2(\text{INT}, \text{MODE} = \text{Comportementale}) = 5.54$
 $p = 0.59$

2.2.14 Modes d'expression × cible

Pairwise : ρ

- $\rho(\text{MODE} = \text{Montrée}, \text{TARGET} = \text{victim}) = -0.17$
 $p < 0.001, n_{\cap} = 82$
- $\rho(\text{MODE} = \text{Désignée}, \text{TARGET} = \text{victim}) = 0.13$
 $p < 0.01, n_{\cap} = 25$
- $\rho(\text{MODE} = \text{Montrée}, \text{TARGET} = \text{bully}) = 0.11$
 $p < 0.05, n_{\cap} = 70$
- $\rho(\text{MODE} = \text{Montrée}, \text{TARGET} = \text{bully_support}) = 0.11$
 $p < 0.05, n_{\cap} = 60$
- $\rho(\text{MODE} = \text{Désignée}, \text{TARGET} = \text{bully}) = -0.09$
 $p = 0.07, n_{\cap} = 4$

Global : χ^2

- $\chi^2(\text{TARGET}, \text{MODE} = \text{Montrée}) = 25.56$
 $p < 0.005$
- $\chi^2(\text{TARGET}, \text{MODE} = \text{Désignée}) = 13.25$
 $p = 0.15$
- $\chi^2(\text{TARGET}, \text{MODE} = \text{Suggérée}) = 6.66$
 $p = 0.67$
- $\chi^2(\text{TARGET}, \text{MODE} = \text{Comportementale}) = 4.55$
 $p = 0.87$

2.2.15 Modes d'expression $\times$ rôle

Pairwise : ρ

- $\rho(\text{MODE} = \text{Montrée}, \text{ROLE} = \text{victim}) = 0.09$
 $p < 0.05, n_{\cap} = 45$
- $\rho(\text{MODE} = \text{Montrée}, \text{ROLE} = \text{conciliator}) = -0.08$
 $p < 0.05, n_{\cap} = 48$
- $\rho(\text{MODE} = \text{Montrée}, \text{ROLE} = \text{bully_support}) = -0.07$
 $p = 0.06, n_{\cap} = 90$
- $\rho(\text{MODE} = \text{Désignée}, \text{ROLE} = \text{bully_support}) = 0.07$
 $p = 0.09, n_{\cap} = 25$
- $\rho(\text{MODE} = \text{Montrée}, \text{ROLE} = \text{bully}) = 0.06$
 $p = 0.15, n_{\cap} = 50$

Global : χ^2

- $\chi^2(\text{ROLE}, \text{MODE} = \text{Montrée}) = 15.37$
 $p < 0.005$
- $\chi^2(\text{ROLE}, \text{MODE} = \text{Désignée}) = 4.60$
 $p = 0.33$
- $\chi^2(\text{ROLE}, \text{MODE} = \text{Comportementale}) = 3.21$
 $p = 0.52$
- $\chi^2(\text{ROLE}, \text{MODE} = \text{Suggérée}) = 0.66$
 $p = 0.96$

2.2.17 Modes d'expression $\times$ contexte

Pairwise : ρ

- $\rho(\text{MODE} = \text{Montrée}, \text{CTX} = \text{OTH}) = -0.13$
 $p < 0.005, n_{\cap} = 18$
- $\rho(\text{MODE} = \text{Montrée}, \text{CTX} = \text{ATK}) = 0.12$
 $p < 0.005, n_{\cap} = 127$
- $\rho(\text{MODE} = \text{Suggérée}, \text{CTX} = \text{CR}) = 0.07$
 $p = 0.17, n_{\cap} = 3$
- $\rho(\text{MODE} = \text{Comportementale}, \text{CTX} = \text{ATK}) = 0.07$
 $p = 0.11, n_{\cap} = 17$
- $\rho(\text{MODE} = \text{Désignée}, \text{CTX} = \text{CR}) = 0.07$
 $p = 0.20, n_{\cap} = 3$

Global : χ^2


- $\chi^2(\text{CTX}, \text{MODE} = \text{Montrée}) = 19.34$
 $p < 0.01$
- $\chi^2(\text{CTX}, \text{MODE} = \text{Comportementale}) = 9.08$
 $p = 0.25$
- $\chi^2(\text{CTX}, \text{MODE} = \text{Désignée}) = 7.53$
 $p = 0.38$
- $\chi^2(\text{CTX}, \text{MODE} = \text{Suggérée}) = 6.77$
 $p = 0.45$

2.2.18 Points d'attention

- Le maximum identifié est $|\rho| = 0.75$, porté par Colère–Montrée.

3. Tests du modèle EMOTYC

3.1 Qu'est-ce qu'EMOTYC ?




3.2.1 Schéma d'annotation émotionnelle

- Les corpus sont représentés au niveau phrastique par un vecteur multi-label.
- Les 12 colonnes émotionnelles sont : Admiration, Autre, Colère, Culpabilité, Dégoût, Embarras, Fierté, Jalousie, Joie, Peur, Surprise et Tristesse.
- Les proportions ci-dessous sont calculées sur les activations positives de ces 12 colonnes.
- Une phrase pouvant porter plusieurs émotions, le dénominateur est le nombre total d'activations émotionnelles, et non le nombre de phrases.

3.2.2 Distributions des émotions dans les corpus


Corpus EmoTextToKids



Corpus de tweets




extrémiste



non extrémiste

Corpus de cyberharcèlement



Références : EmoTextToKids, Etienne (2023) ; tweets, Dragos et al. (2022) ; cyberharcèlement, Ollagnier et al. (2024).

3.2.3 Taille des corpus

Référence	Corpus	Taille
Etienne (2023)	EmoTextToKids	27 911 phrases
Dragos et al. (2022)	Textes extrémistes / radicaux	1 129 textes
Dragos et al. (2022)	Textes non-extrémistes / non-radicaux	599 textes
Annotations CyberAggAdo	CyberAggAdo	781 messages

3.2.4 Performances EMOTYC

Référence	Corpus	Précision	Rappel	F1
Etienne (2023)	EmoTextToKids	0,90	0,89	0,90
Dragos et al. (2022)	Extrémisme	0,80	0,25	0,38
Annotations CyberAggAdo	CyberAggAdo	0,49	0,46	0,47


Pour EmoTextToKids et CyberAggAdo, les métriques sont micro-moyennées sur les 19 labels EMOTYC à partir des JSON de résultats.

3.2.5 Proportions extraites des XLSX

Émotion	EmoTextToKids		CyberAggAdo	
	n	%	n	%
Admiration	211	3,2 %	0	0,0 %
Autre	1270	19,4 %	62	12,4 %
Colère	1180	18,1 %	289	58,0 %
Culpabilité	19	0,3 %	3	0,6 %
Dégoût	52	0,8 %	80	16,1 %
Embarras	162	2,5 %	2	0,4 %
Fierté	202	3,1 %	3	0,6 %
Jalousie	7	0,1 %	6	1,2 %
Joie	888	13,6 %	30	6,0 %
Peur	1047	16,0 %	4	0,8 %
Surprise	824	12,6 %	5	1,0 %
Tristesse	673	10,3 %	14	2,8 %

EmoTextToKids : 27 911 phrases, 6 535 activations émotionnelles. CyberAggAdo : 781 messages, 498 activations émotionnelles.

3.3 Méthodologie utilisée pour les tests de performance



3.3.1 Métriques utilisées

La précision mesure la fiabilité des prédictions positives :

$$\text{Precision} = \frac{TP}{TP + FP}$$

Le rappel mesure la capacité du modèle à retrouver les instances réellement positives :

$$\text{Recall} = \frac{TP}{TP + FN}$$

3.3.2 Interpréter les baisses de performance

- Une baisse de précision suggère que certains indices lexicaux ou contextuels valides dans TTK deviennent trompeurs dans CyberAggAdoLarge.
- Une baisse de rappel suggère que l'émotion concernée est exprimée dans CyberAggAdoLarge par des formes lexicales, discursives ou contextuelles différentes de celles apprises sur TTK. EMOTYC n'ayant jamais vu ces formes, il ne les détecte pas ou les associe à tort à un autre label émotionnel.

3.4.1 Ce que mesure la heatmap

$$\Delta_m(\ell) = m_{\text{TextToKids}}(\ell) - m_{\text{CyberAggAdo}}(\ell)$$

- Les colonnes comparent F_1 , la précision et le rappel, label par label.
- La couleur encode $|\Delta|$: vert clair si les performances sont proches, orange/rouge si l'écart est fort.
- Une valeur positive signifie que le modèle performe mieux sur TextToKids que sur CyberAggAdo.

Corpus	Unités textuelles
TextToKids	27 911
CyberAggAdo	781

Configuration : template avec contexte, seuil 0.5, comparaison directe des résumés JSON.

3.4.2 Heatmap compacte des principaux labels

Label	Cyber	ΔF_1	ΔP	ΔR
Émo	398	+0.27	+0.31	+0.23
Base	363	+0.37	+0.29	+0.43
Montrée	300	+0.41	+0.42	+0.41
Colère	289	+0.46	+0.42	+0.49
Autre	62	+0.76	+0.78	+0.68

Lecture : 4 labels les plus représentés dans CyberAggAdoLarge, plus le plus fort décrochage robuste. $\Delta > 0$ indique une performance supérieure sur TextToKids ; la couleur indique l'amplitude, pas le sens.

3.4.3 Signal principal : forte perte hors domaine

+0.4570

Macro F_1

écart TextToKids – CyberAggAdo

+0.4236

Micro F_1

écart TextToKids – CyberAggAdo

781

unités CyberAggAdo

contre 27 911 pour TextToKids

- Le modèle conserve une détection globale de l'émotion, mais les performances baissent nettement en transfert.
- Les labels fréquents dans CyberAggAdoLarge montrent déjà un décrochage substantiel : *Émo* ($\Delta F_1 = +0.27$), *Base* (+0.37), *Montrée* (+0.41), *Colère* (+0.46).
- Le décalage touche à la fois la précision et le rappel, ce qui suggère des faux positifs et des faux négatifs hors domaine.

3.4.4 Labels concentrant le décrochage

Label	Cyber	TTK	ΔF_1	ΔP	ΔR
Autre	62	1 270	+0.76	+0.78	+0.68
Suggérée	54	1 909	+0.73	+0.67	+0.74
Désignée	55	1 499	+0.56	+0.50	+0.60
Colère	289	1 180	+0.46	+0.42	+0.49
Montrée	300	971	+0.41	+0.42	+0.41
Base	363	4 133	+0.37	+0.29	+0.43

- Le mode *Suggérée* décroche fortement : les indices contextuels appris sur TextToKids transfèrent mal vers les messages de cyberharcèlement.
- *Autre* est le plus grand écart parmi les labels avec au moins 50 occurrences positives dans CyberAggAdoLarge.
- *Colère* et *Montrée* restent suffisamment représentés pour signaler une vraie difficulté, pas seulement un bruit d'effectif.


3.4.5 Points de vigilance

- Les labels très rares dans CyberAggAdoLarge doivent être interprétés avec prudence : *Admiration* a 0 occurrence positive, *Embarras* 2, *Fierté* 3, *Peur* 4.
- La couleur ne distingue pas le signe : une case claire peut aussi correspondre à une absence de cas suffisants pour comparer.
- La heatmap sert surtout à localiser les zones de non-transférabilité ; l'analyse qualitative des erreurs reste nécessaire pour expliquer les mécanismes.


Conclusion : EMOTYC apprend bien le domaine TextToKids, mais les formes discursives de CyberAggAdoLarge changent assez pour dégrader la généralisation, notamment sur les modes d'expression et certains labels émotionnels.

4. Tests avec des classifieurs linéaires

4.1 Classifieurs linéaires utilisés



4.2 Comparaison des performances des classifieurs linéaires aux performances d'EMOTYC



Références

- [1] Dragos, V., Battistelli, D., Etienne, A., and Constable, Y. (2022). *Angry or sad ? emotion annotation for extremist content characterisation*. Proceedings of the Thirteenth Language Resources and Evaluation Conference, 193–201.
- [2] Etienne, A. (2023). *Analyse automatique des émotions dans les textes : contributions théoriques et applicatives dans le cadre de l'étude de la complexité des textes pour enfants*. PhD thesis, Université de Nanterre-Paris X.
- [3] Dragos, V., and Constable, Y. (2023). *Comparison of Classification Techniques for Extremism Detection in French Social Media*. 2023 26th International Conference on Information Fusion (FUSION), 1–6. IEEE.
- [4] Dragos, V., Battistelli, D., Sow, F., and Etienne, A. (2024). *Exploring the Emotional Dimension of French Online Toxic Content*. Proceedings of the 2024 Joint International Conference on Computational Linguistics, Language Resources and Evaluation (LREC-COLING 2024), 6945–6954.
- [5] Étienne, A., Battistelli, D., and Lecorvé, G. (2024). *Emotion Identification for French in Written Texts : Considering their Modes of Expression as a Step Towards Text Complexity Analysis*. arXiv :2405.14385.
- [6] Battistelli, D., Benamara, F., and Patti, V. (2025). *Introduction to the Special Issue of the TAL Journal on Abusive Language : Linguistic Resources, Methods and Applications*. Traitement Automatique des Langues, 65(3), 7–20.