

Transferabilité d'EMOTYC

Lecture de la heatmap des deltas TextToKids → CyberAggAdo

Heatmap source : `results/heatmap_delta.html`
Script source : `visualizations/delta_heatmap.py`

Ce que mesure la heatmap

$$\Delta_m(\ell) = m_{\text{TextToKids}}(\ell) - m_{\text{CyberAggAdo}}(\ell)$$

- ▶ Les colonnes comparent F_1 , la précision et le rappel, label par label.
- ▶ La couleur encode $|\Delta|$: vert clair si les performances sont proches, orange/rouge si l'écart est fort.
- ▶ Une valeur positive signifie que le modèle performe mieux sur TextToKids que sur CyberAggAdo.

Corpus	Unités textuelles
TextToKids	27 911
CyberAggAdo	781

Configuration : template avec contexte, seuil 0.5, comparaison directe des résumés JSON.

Heatmap compacte des principaux labels

Label	Cyber	ΔF_1	ΔP	ΔR
Émo	398	+0.27	+0.31	+0.23
Base	363	+0.37	+0.29	+0.43
Montrée	300	+0.41	+0.42	+0.41
Colère	289	+0.46	+0.42	+0.49
Autre	62	+0.76	+0.78	+0.68

Lecture : 4 labels les plus représentés dans CyberAggAdo, plus le plus fort décrochage robuste. $\Delta > 0$ indique une performance supérieure sur TextToKids; la couleur indique l'amplitude, pas le sens.

Signal principal : forte perte hors domaine

+0.4570

Macro F_1

écart TextToKids – CyberAggAdo

+0.4236

Micro F_1

écart TextToKids – CyberAggAdo

781

unités CyberAggAdo

contre 27 911 pour TextToKids

- ▶ Le modèle conserve une détection globale de l'émotion, mais les performances baissent nettement en transfert.
- ▶ Les labels fréquents dans CyberAggAdo montrent déjà un décrochage substantiel : *Émo* ($\Delta F_1 = +0.27$), *Base* (+0.37), *Montrée* (+0.41), *Colère* (+0.46).
- ▶ Le décalage touche à la fois la précision et le rappel, ce qui suggère des faux positifs et des faux négatifs hors domaine.

Labels qui concentrent le décrochage

Label	Cyber	TTK	ΔF_1	ΔP	ΔR
Autre	62	1 270	+0.76	+0.78	+0.68
Suggérée	54	1 909	+0.73	+0.67	+0.74
Désignée	55	1 499	+0.56	+0.50	+0.60
Colère	289	1 180	+0.46	+0.42	+0.49
Montrée	300	971	+0.41	+0.42	+0.41
Base	363	4 133	+0.37	+0.29	+0.43

- ▶ Le mode *Suggérée* décroche fortement : les indices contextuels appris sur TextToKids transfèrent mal vers les messages de cyberharcèlement.
- ▶ *Autre* est le plus grand écart parmi les labels avec au moins 50 occurrences positives dans CyberAggAdo.
- ▶ *Colère* et *Montrée* restent suffisamment représentés pour signaler une vraie difficulté, pas seulement un bruit d'effectif.

Points de vigilance

- ▶ Les labels très rares dans CyberAggAdo doivent être interprétés avec prudence : *Admiration* a 0 occurrence positive, *Embarras* 2, *Fierté* 3, *Peur* 4.
- ▶ La couleur ne distingue pas le signe : une case claire peut aussi correspondre à une absence de cas suffisants pour comparer.
- ▶ La heatmap sert surtout à localiser les zones de non-transférabilité ; l'analyse qualitative des erreurs reste nécessaire pour expliquer les mécanismes.

Conclusion : EMOTYC apprend bien le domaine TextToKids, mais les formes discursives de CyberAggAdo changent assez pour dégrader la généralisation, notamment sur les modes d'expression et certains labels émotionnels.